**TRƯỜNG ĐẠI HỌC VĂN LANG**
**KHOA CÔNG NGHỆ THÔNG TIN**

# BÁO CÁO BÀI TẬP 1
# HỌC PHẦN: CHUYÊN ĐỀ TỐT NGHIỆP 1

***Đề tài:***

# PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG SMART CRM – MEKONG MOBILE

***Luồng nghiệp vụ L7 – Chất lượng dữ liệu khách hàng***
*Track: DA (Data Analytics)*

**SVTH: Dương Diễm My**
**MSSV: 2374802010318**
**Lớp: 261_71ITGR40203_03**
**Giảng viên: ThS. Nguyễn Minh Tân**
**Ngày nộp: 09/10/2026**
**Link GitHub: https://github.com/Duongmy2612/smartcrm-2374802010318-customer-data-quality**

**TP. Hồ Chí Minh - Năm 2026**

# MỤC LỤC

MỤC 1 – BẢN SRS RÚT GỌN ..... 3
1.1. Giới thiệu, phạm vi và bảng thuật ngữ ..... 3
1.2. Các bên liên quan và vai trò ..... 4
1.3. Yêu cầu chức năng và User Story ..... 5
1.4. Yêu cầu phi chức năng (mỗi yêu cầu có ngưỡng số) ..... 6
1.5. Ràng buộc và quy tắc nghiệp vụ ..... 6
1.6. Bảng truy vết yêu cầu ..... 7
MỤC 2 – USE CASE ..... 8
2.1. Use Case Diagram ..... 8
2.2. Đặc tả use case quan trọng nhất – UC5 ..... 9
MỤC 3 – THIẾT KẾ KIẾN TRÚC ..... 10
3.1. Sơ đồ kiến trúc ..... 10
3.2. Lập luận lựa chọn kiến trúc (gắn với yêu cầu phi chức năng) ..... 11
MỤC 4 – MÔ HÌNH DỮ LIỆU THEO CHUYÊN NGÀNH (TRACK DA) ..... 12
4.1. Dữ liệu nguồn (đã đo) ..... 12
4.2. Sơ đồ luồng dữ liệu từ nguồn đến kho ..... 14
4.3. Mô hình dữ liệu tầng tác nghiệp (schema ops) ..... 14
4.4. Lược đồ kho dữ liệu (schema dwh) ..... 15
4.5. Bộ quy tắc chất lượng (nội dung dim_rule) và số đo cơ sở ..... 18
MỤC 5 – WIREFRAME ..... 19
PHỤ LỤC A – TỪ ĐIỂN DỮ LIỆU TẦNG TÁC NGHIỆP (SCHEMA ops) ..... 23
PHỤ LỤC B – RÀ SOÁT VÀ NHẬT KÝ THAY ĐỔI SO VỚI BẢN BUỔI 4 ..... 25
B.1. Tự kiểm theo bảng tiêu chí kỹ thuật tối thiểu ..... 25
B.2. Sáu phép kiểm nhất quán và soi lỗi ERD ..... 25
B.3. Nhật ký thay đổi ..... 26
B.4. Ánh xạ User Story Buổi 4 → Buổi 6 ..... 27
PHỤ LỤC C – BẢNG KHAI BÁO SỬ DỤNG CÔNG CỤ AI (BẮT BUỘC) ..... 28

# MỤC 1 – BẢN SRS RÚT GỌN

## 1.1. Giới thiệu, phạm vi và bảng thuật ngữ

**Bối cảnh.** Mekong Mobile (24 cửa hàng, 6 trung tâm bảo hành, khoảng 65.000 khách hàng) chưa có hệ thống CRM. Dữ liệu khách hàng nằm rải rác ở file Excel của từng cửa hàng, tin nhắn Zalo và sổ tay trung tâm bảo hành; một khách có thể tồn tại nhiều lần với nhiều số điện thoại (vấn đề V1 – case study ánh xạ tới L1, L7; ước tính 18–22% hồ sơ lặp). Marketing cũng chưa phân khúc được khách hàng nên phải gửi khuyến mãi cho toàn bộ danh sách (V5, thuộc L1, L9) – muốn phân khúc, trước hết mỗi khách phải là một hồ sơ duy nhất, đó là việc của L7. Đo trên tệp mẫu `customers_raw.csv` (67.037 dòng): 18,48% hồ sơ có số điện thoại là hồ sơ lặp của một khách đã có, 6,17% hồ sơ thiếu số điện thoại và 28,40% hồ sơ ghi số điện thoại sai dạng (84…, +84…, có dấu cách hoặc dấu chấm).

**Luồng nghiệp vụ chọn:** L7 – Chất lượng dữ liệu khách hàng (đã được giảng viên duyệt ở Buổi 2). **Phạm vi một câu:** *Nạp tệp khách hàng thô, chuẩn hóa số điện thoại và họ tên, phát hiện cặp hồ sơ nghi trùng bằng so khớp mờ để Nhân viên Marketing xác nhận gộp hoặc giữ riêng, rồi đo và báo cáo chỉ số mức độ sạch dữ liệu theo từng đợt nạp.*

**Hệ thống làm:**

- Nạp tệp khách hàng thô (CSV/Excel) theo đợt nạp; chuẩn hóa số điện thoại và họ tên (UC1, UC2).
- Phát hiện cặp nghi trùng bằng so khớp mờ; Nhân viên Marketing xem và xác nhận Gộp hoặc Giữ riêng từng cặp (UC3, UC4, UC5).
- Cấu hình bộ quy tắc chất lượng dữ liệu; đo chỉ số mức độ sạch của từng đợt trước và sau làm sạch (UC6, UC7).
- Dashboard mức độ sạch theo thời gian và xuất danh sách hồ sơ lỗi để cửa hàng sửa tại nguồn (UC8, UC9).

**Chủ ý KHÔNG làm (mức WON'T của MoSCoW):**

| Mã | Không làm | Lý do |
|---|---|---|
| W1 | Tự động gộp cặp nghi trùng có điểm tương đồng cao mà không cần xác nhận (US10 của bản Buổi 4). | Gộp nhầm hai người rất khó hoàn tác; đo được 4 nhóm hồ sơ cùng số điện thoại nhưng là hai người khác nhau (khác họ tên và ngày ghi nhận) – gộp tự động sẽ sai ngay trên dữ liệu mẫu (QL7-01). |
| W2 | Xử lý dữ liệu đơn hàng, bảo hành, kho linh kiện; phân khúc khách hàng (L1); dự báo khách rời bỏ (L9). | Thuộc luồng nghiệp vụ khác; L7 chỉ làm sạch dữ liệu khách hàng. |
| W3 | Gửi tin khuyến mãi/chiến dịch thực tế; tích hợp trực tiếp hệ thống bán hàng; đăng nhập một lần (SSO); triển khai máy chủ. | Ngoài phạm vi prototype của Chuyên đề tốt nghiệp 1. |

**Bảng 1.1 – Bảng thuật ngữ (mỗi khái niệm chỉ dùng một tên trong SRS, sơ đồ, ERD và wireframe)**

| Thuật ngữ | Định nghĩa | Tên kỹ thuật |
|---|---|---|
| **Hồ sơ khách hàng** | Một bản ghi mô tả một khách hàng: họ tên, số điện thoại, email, địa chỉ. | stg_customer, customer_clean |
| **Tệp khách hàng thô** | Tệp CSV/Excel chưa làm sạch, mỗi dòng là một hồ sơ; cột bắt buộc ho_ten, so_dien_thoai (mẫu: customers_raw.csv). Trên Use Case, nơi cung cấp tệp là actor hệ thống ngoài "Tệp nguồn Excel/CSV". | _ |
| **Đợt nạp** | Một lần nạp một tệp khách hàng thô; có mã, thời điểm, người nạp và đơn vị nguồn. | load_batch |
| **Đơn vị nguồn** | Cửa hàng hoặc kênh cung cấp tệp của đợt nạp; căn cứ phân quyền xem dữ liệu (QT-14). | source_unit |

| Thuật ngữ | Định nghĩa | Tên kỹ thuật |
|---|---|---|
| **Bảng tạm** | Nơi lưu hồ sơ thô sau khi nạp, trước khi làm sạch. | stg_customer |
| **Hồ sơ thô** | Một dòng của tệp khách hàng thô đã nạp vào bảng tạm, giữ nguyên giá trị gốc. | stg_customer (1 dòng) |
| **Chuẩn hóa** | Đưa số điện thoại về dạng 0xxxxxxxxx (QT-02) và họ tên về một dạng thống nhất (FR-02, FR-03). | phone_norm, name_norm |
| **Khóa tên** | Họ tên không dấu, chữ thường, bỏ khoảng trắng thừa; tạo khi phát hiện cặp nghi trùng (FR-04) để chấm điểm tương đồng (QL7-03). | name_key |
| **Hồ sơ lỗi** | Hồ sơ thô có mã lỗi (thiếu hoặc sai số điện thoại, thiếu họ tên) nên không được đưa vào hồ sơ đã làm sạch. | error_code |
| **Hồ sơ đã làm sạch** | Hồ sơ đã chuẩn hóa, có số điện thoại hợp lệ và không trùng với hồ sơ đang hiệu lực nào khác. | customer_clean |
| **Cặp nghi trùng** | Hai hồ sơ có khả năng là một người; mỗi hồ sơ trong cặp gọi là hồ sơ nghi trùng. | dup_candidate |
| **Hồ sơ lặp** | Hồ sơ có cùng số điện thoại chuẩn hóa với một hồ sơ nạp sớm hơn; mỗi hồ sơ lặp sinh một cặp EXACT_PHONE (QL7-02). Tỉ lệ hồ sơ lặp = số hồ sơ lặp / số hồ sơ có số điện thoại. | – (đếm theo phone_norm) |
| **Điểm tương đồng** | Số từ 0 đến 100 đo mức giống nhau của hai hồ sơ trong cặp nghi trùng (QL7-03). | score |
| **Chờ xử lý / Gộp / Giữ riêng** | Ba trạng thái của cặp nghi trùng: chưa quyết định; đã hợp nhất thành một hồ sơ (có xác nhận); đã xác định là hai khách khác nhau. | PENDING / MERGED / KEEP_SEPARATE |
| **Hồ sơ gốc** | Hồ sơ được chọn khi gộp để lấy giá trị cho hồ sơ đã làm sạch sau gộp; trường trống được bổ sung từ hồ sơ còn lại. | survivor_stg_id |
| **Ngừng sử dụng** | Xóa mềm: đánh dấu không dùng nữa, giữ nguyên lịch sử (QT-13). | is_active = false |
| **Quy tắc chất lượng dữ liệu** | Một tiêu chí đánh giá hồ sơ (DQ-01 … DQ-06), có loại, trường áp dụng, trọng số và ngưỡng đạt. | dq_rule / dim_rule |
| **Lần đo** | Một lần đánh giá các quy tắc đang bật trên một đợt nạp, ở giai đoạn TRƯỚC (trên giá trị thô) hoặc SAU làm sạch; riêng quy tắc không trùng (DQ-05) luôn so theo số đã chuẩn hóa. | dq_result / fact_dq_check |
| **Chỉ số mức độ sạch** | Điểm 0–100 của một đợt nạp tại một lần đo = Σ(trọng số × tỉ lệ đạt) × 100 (QL7-06); tính trong view, không lưu. | v_batch_score |
| **Kho dữ liệu** | Schema dwh dạng lược đồ hình sao (bảng fact, bảng dimension) phục vụ dashboard; chỉ chứa số đếm, không chứa dữ liệu cá nhân. | dwh |

## 1.2. Các bên liên quan và vai trò

### Bảng 1.2 – Actor: được làm và không được làm

| Actor | Loại | Được làm | Không được làm |
|---|---|---|---|
| **Nhân viên Marketing** | Người dùng chính (Bộ phận Marketing, 5 người; thuộc văn phòng công ty nên phạm vi dữ liệu là toàn công ty) | Nạp tệp (UC1); chạy phát hiện cặp nghi trùng (UC3); xem danh sách và xác nhận Gộp/Giữ riêng (UC4, UC5); xem dashboard (UC8); xuất danh sách hồ sơ lỗi (UC9). | Không cấu hình quy tắc chất lượng (UC6); không xem số điện thoại đầy đủ (QT-15); không xóa hồ sơ (QT-13). |
| **Quản lý cửa hàng** | Người dùng (24 người) | Cấu hình quy tắc chất lượng dùng chung toàn công ty (UC6) – mỗi lần lưu ghi người sửa gần nhất (dq_rule.updated_by) và tạo phiên bản mới ở dim_rule (SCD loại 2); xem dashboard của đơn vị mình (UC8); xuất hồ sơ lỗi của đơn vị mình để sửa tại nguồn (UC9); xem số điện thoại đầy đủ. | Không quyết định Gộp/Giữ riêng (thuộc Marketing); không xem dữ liệu của đơn vị khác (QT-14); không xóa hồ sơ (QT-13). |
| **Tệp nguồn Excel/CSV** | Hệ thống ngoài (actor phụ) | Cung cấp hồ sơ thô cho UC1. | Không ghi trực tiếp vào CSDL; tệp thiếu cột ho_ten hoặc so_dien_thoai bị từ chối cả đợt. |

## 1.3. Yêu cầu chức năng và User Story

### Bảng 1.3 – Yêu cầu chức năng (kiểm chứng được)

| Mã | Yêu cầu chức năng | MoSCoW |
|---|---|---|
| **FR-01** | Hệ thống cho phép nạp tệp CSV/Excel vào bảng tạm; mỗi lần nạp tạo một đợt nạp ghi tên tệp, giá trị băm SHA-256, đơn vị nguồn, người nạp, thời điểm và số dòng; từ chối cả đợt khi thiếu cột ho_ten hoặc so_dien_thoai (báo tên cột thiếu, bảng tạm không đổi); cảnh báo khi tệp trùng giá trị băm với một đợt đã nạp. | MUST |
| **FR-02** | Hệ thống chuẩn hóa số điện thoại về 10 chữ số bắt đầu bằng 0 (QT-02): bỏ dấu cách, dấu chấm, dấu gạch; đổi tiền tố +84 hoặc 84 thành 0; gắn mã lỗi MISSING_PHONE khi trống, INVALID_PHONE khi không quy về được mẫu ^0\d{9}$ và MISSING_NAME khi họ tên trống; ghi hồ sơ không có mã lỗi và có số chưa thuộc hồ sơ đang hiệu lực nào vào customer_clean; hồ sơ lặp không tạo hồ sơ mới mà chờ quyết định (QT-01, QL7-04). | MUST |
| **FR-03** | Hệ thống chuẩn hóa họ tên để hiển thị thống nhất (name_norm): bỏ khoảng trắng thừa, viết hoa chữ cái đầu mỗi từ, giữ nguyên dấu tiếng Việt. | SHOULD |
| **FR-04** | Hệ thống phát hiện cặp nghi trùng: tạo khóa tên không dấu, chữ thường (name_key); chỉ so sánh hai hồ sơ cùng 5 số đầu hoặc cùng 5 số cuối của số điện thoại chuẩn hóa (blocking); tính điểm tương đồng theo QL7-03; ghi cặp ở trạng thái Chờ xử lý khi cùng số điện thoại (EXACT_PHONE) hoặc điểm ≥ ngưỡng 85 (FUZZY); không đề xuất lại cặp đã Giữ riêng (QL7-05). | MUST |
| **FR-05** | Hệ thống hiển thị danh sách cặp nghi trùng sắp theo điểm tương đồng giảm dần, lọc theo trạng thái và khoảng điểm, và cho xem hai hồ sơ cạnh nhau với các trường khác nhau được đánh dấu. | MUST |
| **FR-06** | Hệ thống cho phép xác nhận Gộp (chọn hồ sơ gốc) hoặc Giữ riêng từng cặp; khi gộp, trong cùng một giao dịch, giữ đúng một hồ sơ đang hiệu lực trong customer_clean mang giá trị của hồ sơ gốc và chuyển hồ sơ còn lại sang ngừng sử dụng (hoặc gắn hồ sơ thô của nó vào hồ sơ được giữ nếu nó chưa có trong customer_clean); ghi người quyết định, thời điểm, lý do; không bao giờ tự động gộp (QL7-01). | MUST |
| **FR-07** | Hệ thống cho phép thêm, sửa, tắt quy tắc chất lượng dữ liệu (loại, trường áp dụng, trọng số, ngưỡng đạt); chỉ lưu khi tổng trọng số các quy tắc đang bật bằng 1,00. | SHOULD |
| **FR-08** | Hệ thống đánh giá các quy tắc đang bật trên từng đợt nạp và ghi số hồ sơ được kiểm, số hồ sơ đạt cho mỗi quy tắc ở hai giai đoạn: TRƯỚC (trên giá trị thô của đợt; riêng DQ-05 so theo số đã chuẩn hóa) và SAU (sau chuẩn hóa; đo lại sau mỗi lần Gộp/Giữ riêng). | MUST |
| **FR-09** | Hệ thống hiển thị dashboard: chỉ số mức độ sạch theo đợt nạp và theo ngày (TRƯỚC/SAU), phân rã theo quy tắc, số cặp nghi trùng theo trạng thái và phân bố điểm; lọc theo khoảng ngày, đơn vị nguồn, đợt nạp. | SHOULD |
| **FR-10** | Hệ thống xuất danh sách hồ sơ lỗi của một đợt nạp (kèm mã lỗi) ra tệp CSV. | COULD |
| **FR-11** | Hệ thống che số điện thoại dạng 090****567 trên mọi màn hình với vai trò không phải Quản lý hoặc Ban giám đốc (QT-15). | MUST |

### Bảng 1.4 – User Story (7 story, chuẩn INVEST)

| Mã | User Story | MoSCoW |
|---|---|---|
| **US1** | Là **Nhân viên Marketing**, tôi muốn nạp tệp khách hàng thô (CSV/Excel) và nhận số điện thoại đã ở dạng chuẩn 0xxxxxxxxx để không phải sửa tay hàng nghìn số sai dạng (V1; đo được 28,40% hồ sơ ghi số sai dạng). | MUST |
| **US2** | Là **Nhân viên Marketing**, tôi muốn họ tên khách được chuẩn hóa về một dạng thống nhất để danh sách hiển thị gọn và gọi đúng tên khách (đo được 2.651 họ tên viết IN HOA, 1.933 viết thường, 1.346 thừa khoảng trắng). | SHOULD |
| **US3** | Là **Nhân viên Marketing**, tôi muốn hệ thống tự phát hiện các cặp hồ sơ nghi trùng kèm điểm tương đồng để không phải dò thủ công khoảng 18% hồ sơ lặp (V1). | MUST |
| **US4** | Là **Nhân viên Marketing**, tôi muốn xem danh sách cặp nghi trùng sắp theo điểm tương đồng và xác nhận Gộp hoặc Giữ riêng từng cặp để hồ sơ được hợp nhất đúng mà không gộp nhầm hai người khác nhau. | MUST |
| **US5** | Là **Quản lý cửa hàng**, tôi muốn cấu hình trọng số và ngưỡng của các quy tắc chất lượng dữ liệu để tiêu chí đánh giá phù hợp từng giai đoạn mà không cần sửa mã. | SHOULD |
| **US6** | Là **Quản lý cửa hàng**, tôi muốn xem chỉ số mức độ sạch của từng đợt nạp và xu hướng theo thời gian để biết dữ liệu đạt hay chưa và đang cải thiện hay xấu đi mà không phải đếm tay trên từng tệp Excel. | SHOULD |
| **US7** | Là **Quản lý cửa hàng**, tôi muốn xuất danh sách hồ sơ lỗi ra tệp CSV để cửa hàng bổ sung số điện thoại tại nguồn, vì 6,17% hồ sơ thiếu số không thể sửa bằng làm sạch. | COULD |

*Ba story MUST (US1, US3, US4) có tiêu chí chấp nhận Given–When–Then ở docs/srs.md; bảng ánh xạ 11 story của Buổi 4 sang 7 story hiện tại ở Phụ lục B.4.*

## 1.4. Yêu cầu phi chức năng (mỗi yêu cầu có ngưỡng số)

**Bảng 1.5 – Yêu cầu phi chức năng**

| Mã | Nhóm | Yêu cầu (ngưỡng đo được) | Cách kiểm chứng |
|---|---|---|---|
| **NFR-01** | Hiệu năng xử lý | Nạp và chuẩn hóa tệp 8.000 dòng ≤ 60 giây; phát hiện cặp nghi trùng trên 8.000 hồ sơ ≤ 120 giây. | Đo 3 lần trên máy phát triển, lấy giá trị lớn nhất. |
| **NFR-02** | Độ chính xác chuẩn hóa | ≥ 99% số điện thoại có giá trị được chuẩn hóa đúng trên tập 200 dòng gán nhãn tay có đủ 5 dạng ghi (chuẩn, 84…, +84…, dấu cách, dấu chấm). | Kiểm thử tự động so với nhãn tay. |
| **NFR-03** | Chất lượng phát hiện trùng | Trên tập 300 cặp gán nhãn tay, ở ngưỡng 85: precision ≥ 85% và recall ≥ 80%. | Tính precision/recall; chỉnh ngưỡng nếu chưa đạt. |
| **NFR-04** | Toàn vẹn dữ liệu | 100% số điện thoại của hồ sơ đang hiệu lực trong customer_clean khớp ^0\d{9}$ và không trùng nhau (QT-01, QT-02); 0 hồ sơ bị xóa vật lý (QT-13). | Truy vấn kiểm tra sau mỗi đợt nạp. |
| **NFR-05** | Tái lập | Nạp lại cùng tệp vào CSDL mới khởi tạo với cùng cấu hình quy tắc cho kết quả giống 100% (số cặp nghi trùng, chỉ số mức độ sạch trước khi có quyết định); chỉ số của các lần đo đã có không đổi khi cấu hình quy tắc thay đổi sau đó; mọi bước ngẫu nhiên đặt seed = 42 và ghi trong README. | So sánh kết quả hai lần chạy. |
| **NFR-06** | Hiệu năng dashboard | Mỗi khung dashboard tải xong ≤ 5 giây với ≤ 24 đợt nạp. | Đo thời gian tải từng khung. |
| **NFR-07** | Bảo mật | 0 thông tin bí mật (mật khẩu, khóa) trong repo, kết nối chỉ qua .env (không commit); 100% màn hình hiển thị số điện thoại che số với vai trò không phải Quản lý/Ban giám đốc (QT-15). | Quét repo; kiểm tra giao diện theo từng vai trò. |
| **NFR-08** | Truy vết | 100% quyết định Gộp/Giữ riêng có bản ghi người thực hiện, thời điểm và điểm tương đồng. | Đối chiếu dup_candidate với thao tác. |

## 1.5. Ràng buộc và quy tắc nghiệp vụ

**Bảng 1.6 – Quy tắc nghiệp vụ (QT trích Bảng 9.1 của case study; QL7 là quy tắc riêng của luồng)**

| Mã | Quy tắc | Áp dụng ở |
|---|---|---|
| **QT-01** | Số điện thoại khách hàng là duy nhất; khi số đã tồn tại, hiển thị hồ sơ có sẵn thay vì tạo hồ sơ mới. | FR-02, FR-04, FR-06; UC5 (8b) |
| **QT-02** | Số điện thoại được chuẩn hóa về 10 chữ số bắt đầu bằng 0 trước khi lưu; các dạng +84…, 84…, có dấu cách, dấu chấm đều quy về dạng chuẩn. | FR-02, US1 |
| **QT-13** | Không xóa vật lý hồ sơ khách hàng; chỉ đánh dấu ngừng sử dụng và giữ nguyên lịch sử. | FR-06, NFR-04 |
| **QT-14** | Nhân viên chỉ xem dữ liệu của đơn vị mình; quản lý xem toàn bộ đơn vị mình phụ trách. | FR-09 (lọc theo đơn vị nguồn) |
| **QT-15** | Số điện thoại hiển thị dạng che với mọi vai trò trừ Quản lý và Ban giám đốc. | FR-11, NFR-07 |
| **QL7-01** | Không tự động gộp trong mọi trường hợp (kể cả điểm 100); mọi lần gộp cần Nhân viên Marketing xác nhận. | FR-06; UC5 |
| **QL7-02** | Tạo cặp nghi trùng khi hai hồ sơ cùng số điện thoại chuẩn hóa (EXACT_PHONE) hoặc có điểm tương đồng ≥ ngưỡng (mặc định 85, khai báo trong cấu hình ứng dụng) (FUZZY). Nhóm k hồ sơ cùng số tạo k − 1 cặp, mỗi cặp ghép hồ sơ nạp sớm nhất với một hồ sơ còn lại. | FR-04 |
| **QL7-03** | Điểm tương đồng = 0,6 × độ giống số điện thoại + 0,4 × độ giống họ tên. Độ giống số điện thoại = 100 nếu bằng nhau, ngược lại là tỉ lệ giống chuỗi 10 chữ số; độ giống họ tên tính trên name_key, không phân biệt hoa/thường, không phụ thuộc thứ tự từ. | FR-04 |
| **QL7-04** | Hồ sơ không có số điện thoại hợp lệ ở lại bảng tạm với mã lỗi, không vào customer_clean và không tham gia so khớp. | FR-02, FR-10 |
| **QL7-05** | Cặp đã Giữ riêng không được đề xuất lại. | FR-04; UC5 (3a) |

| Mã | Quy tắc | Áp dụng ở |
|---|---|---|
| **QL7-06** | Chỉ số mức độ sạch = Σ(trọng số × tỉ lệ đạt) × 100 trên các quy tắc đang bật (tổng trọng số = 1,00); tỉ lệ đạt = số hồ sơ đạt / số hồ sơ thuộc phạm vi áp dụng của quy tắc. Quy tắc có mẫu số bằng 0 trong đợt (ví dụ tệp không có email) được tính tỉ lệ đạt = 1. Phân loại: ≥ 90 Tốt; từ 75 đến dưới 90 Chấp nhận được; dưới 75 Kém. | FR-07, FR-08, FR-09 |
| **QL7-07** | Gộp hai hồ sơ khác số điện thoại phải chọn số chính; số còn lại vẫn lưu ở hồ sơ thô và hồ sơ ngừng sử dụng (không mất thông tin). | FR-06; UC5 (5a) |

**Ràng buộc dự án và giả định:**

- Prototype chạy cục bộ: Python 3.11 (pandas, rapidfuzz), PostgreSQL, Streamlit; không tích hợp hệ thống thật của doanh nghiệp.
- Dữ liệu mô phỏng của case study; mẫu phát triển 8.000 dòng trích theo cụm số điện thoại với seed = 42 (mục 4.1).
- "Làm từng phần, phần nào xong dùng phần đó" (Phó Tổng giám đốc): L7 được triển khai độc lập, không phụ thuộc luồng khác.
- Người dùng và vai trò khai báo trong cấu hình ứng dụng (prototype); tên đăng nhập được ghi vào loaded_by, decided_by, updated_by.

## 1.6. Bảng truy vết yêu cầu

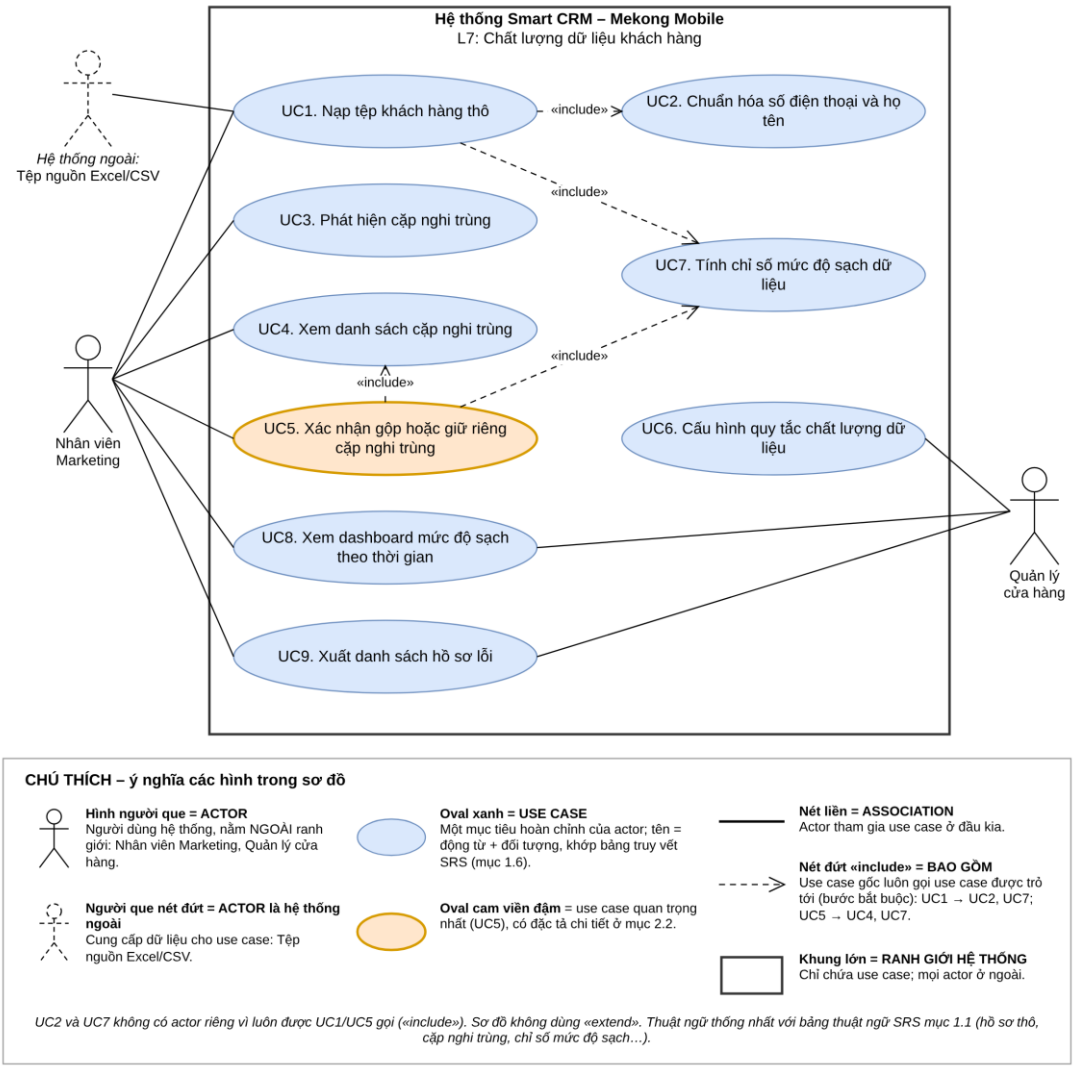
**Bảng 1.7 – Truy vết FR ↔ User Story ↔ Use Case ↔ MoSCoW (kèm bảng dữ liệu và khung màn hình)**

| FR | User Story | Use Case | MoSCoW | Bảng dữ liệu | Màn hình / khung |
|---|---|---|---|---|---|
| **FR-01** | US1 | UC1 | MUST | load_batch, stg_customer → dim_batch | K1 (bộ lọc Đợt nạp, Số hồ sơ được đánh giá) |
| **FR-02** | US1 | UC1, UC2 | MUST | stg_customer (phone_raw, phone_norm, error_code), customer_clean | K2 (DQ-01, DQ-02 trước/sau) |
| **FR-03** | US2 | UC2 | SHOULD | stg_customer (name_norm) | K4 (họ tên hai hồ sơ) |
| **FR-04** | US3 | UC3 | MUST | stg_customer (name_key); dup_candidate → fact_dup_pair | K3 (số cặp, phân bố điểm) |
| **FR-05** | US4 | UC4 | MUST | dup_candidate, stg_customer | K4 (danh sách cặp) |
| **FR-06** | US4 | UC5 | MUST | dup_candidate, customer_clean, stg_customer | K4 (Gộp / Giữ riêng); K3 (trạng thái) |
| **FR-07** | US5 | UC6 | SHOULD | dq_rule → dim_rule | K2 (trọng số, ngưỡng) |
| **FR-08** | US6 | UC7 | MUST | dq_result → fact_dq_check | K1, K2 |
| **FR-09** | US6 | UC8 | SHOULD | fact_dq_check, fact_dup_pair, dim_date, dim_batch, dim_rule | K1, K2, K3 |
| **FR-10** | US7 | UC9 | COULD | stg_customer (error_code) | Tệp CSV hồ sơ lỗi |
| **FR-11** | US4 | UC4, UC5 | MUST | customer_clean, stg_customer (số điện thoại) | K4 (số điện thoại che) |
| **W1 – tự động gộp (không có FR)** | US10 (bản Buổi 4) | UC5 – chỉ gộp khi có xác nhận | WON'T | dup_candidate.status chỉ đổi khi có người quyết định (decided_by) | K4 – không có nút gộp tự động hay gộp hàng loạt |

Đọc theo hàng: 11/11 FR đều có User Story, use case, bảng dữ liệu và khung màn hình; hàng WON'T ghi cách hệ thống bảo đảm điều chủ ý không làm. Đọc theo cột: UC1 – UC9 và US1 – US7 đều xuất hiện ít nhất một lần; 11/11 bảng (6 bảng tác nghiệp, 5 bảng kho) đều phục vụ ít nhất một FR. Mức MoSCoW ghi theo FR: FR-08 là MUST dù US6 là SHOULD, vì UC7 là bước bắt buộc («include») của UC1 và UC5; phần SHOULD của US6 là dashboard (FR-09).

# MỤC 2 – USE CASE

## 2.1. Use Case Diagram




*Hình 2.1 – Use Case Diagram luồng L7 (file gốc docs/usecase.drawio)*

### Bảng 2.1 – Danh sách use case

| UC | Tên use case | Actor | Quan hệ | User Story |
|---|---|---|---|---|
| **UC1** | Nạp tệp khách hàng thô | Nhân viên Marketing; Tệp nguồn Excel/CSV | «include» UC2, UC7 | US1 |
| **UC2** | Chuẩn hóa số điện thoại và họ tên | (UC1 gọi) | – | US1, US2 |
| **UC3** | Phát hiện cặp nghi trùng | Nhân viên Marketing | – | US3 |
| **UC4** | Xem danh sách cặp nghi trùng | Nhân viên Marketing | (UC5 gọi) | US4 |
| **UC5** | Xác nhận gộp hoặc giữ riêng cặp nghi trùng | Nhân viên Marketing | «include» UC4, UC7 | US4 |
| **UC6** | Cấu hình quy tắc chất lượng dữ liệu | Quản lý cửa hàng | – | US5 |
| **UC7** | Tính chỉ số mức độ sạch dữ liệu | (UC1, UC5 gọi) | – | US6 |
| **UC8** | Xem dashboard mức độ sạch theo thời gian | Nhân viên Marketing; Quản lý cửa hàng | – | US6 |
| **UC9** | Xuất danh sách hồ sơ lỗi | Nhân viên Marketing; Quản lý cửa hàng | – | US7 |

So với bản Buổi 4: giữ nguyên 3 actor và 9 use case; bổ sung «include» UC5 → UC7 cho khớp bước 9 của đặc tả UC5 (sau mỗi lần gộp phải đo lại chỉ số); đổi tên UC1, UC3, UC8 theo bảng thuật ngữ; bố trí lại hai cột để các đường không cắt nhau. Sơ đồ đã soát bảy lỗi thường gặp: actor

nằm ngoài ranh giới, tên use case là động từ + đối tượng, có actor không phải người (Tệp nguồn Excel/CSV), không vẽ chi tiết giao diện, có luồng ngoại lệ ở đặc tả, có chú thích, tên khớp SRS.

## 2.2. Đặc tả use case quan trọng nhất – UC5

Chọn UC5 vì đây là bước duy nhất hợp nhất hoặc ngừng sử dụng hồ sơ đã làm sạch và là điểm kiểm soát "không tự động gộp" (QL7-01).

**Bảng 2.2 – Thông tin chung của UC5**

| | |
|---|---|
| **Mã / Tên** | UC5 – Xác nhận gộp hoặc giữ riêng cặp nghi trùng |
| **Actor chính** | Nhân viên Marketing |
| **Mục tiêu** | Quyết định một cặp nghi trùng là cùng một khách (Gộp) hay hai khách khác nhau (Giữ riêng) và cập nhật hồ sơ đã làm sạch tương ứng. |
| **User Story liên quan** | US4 (tiêu chí chấp nhận AC4.2 – AC4.4 trong docs/srs.md) |
| **Điều kiện trước** | Người dùng đã đăng nhập với vai trò Nhân viên Marketing; UC3 đã chạy; có ít nhất một cặp ở trạng thái Chờ xử lý. |
| **Điều kiện sau (thành công)** | Cặp ở trạng thái Gộp hoặc Giữ riêng; customer_clean được cập nhật đúng; có đủ người quyết định, thời điểm, điểm tương đồng (NFR-08); không hồ sơ nào bị xóa vật lý (QT-13); chỉ số mức độ sạch của đợt được đo lại (UC7). |
| **Điều kiện sau (thất bại)** | Dữ liệu không đổi, cặp vẫn ở trạng thái Chờ xử lý. |
| **Quy tắc liên quan** | QT-01, QT-13, QT-15, QL7-01, QL7-05, QL7-07 |

### Luồng chính (Gộp):

1. Nhân viên Marketing mở danh sách cặp nghi trùng (UC4) và chọn một cặp ở trạng thái Chờ xử lý.
2. Hệ thống hiển thị hai hồ sơ cạnh nhau (họ tên đã chuẩn hóa, số điện thoại che theo QT-15, email, địa chỉ, ngày ghi nhận), điểm tương đồng, loại so khớp và đánh dấu các trường khác nhau.
3. Nhân viên chọn quyết định Gộp.
4. Hệ thống yêu cầu chọn hồ sơ gốc.
5. Nhân viên chọn hồ sơ gốc.
6. Hệ thống hiển thị bản xem trước hồ sơ sau gộp: giữ giá trị của hồ sơ gốc, bổ sung trường trống từ hồ sơ còn lại.
7. Nhân viên bấm Xác nhận (có thể nhập lý do).
8. Hệ thống khóa cặp để ghi và kiểm tra lại: cặp vẫn ở trạng thái Chờ xử lý; số điện thoại của hồ sơ sau gộp không trùng với hồ sơ đang hiệu lực nào khác (QT-01).
9. Trong một giao dịch, hệ thống: giữ một hồ sơ trong customer_clean – của bên được chọn làm hồ sơ gốc, hoặc của bên duy nhất đã có trong customer_clean (cặp EXACT_PHONE) – và cập nhật nó theo giá trị của hồ sơ gốc, bổ sung trường trống từ hồ sơ còn lại; nếu bên kia cũng có trong customer_clean thì chuyển hồ sơ đó sang ngừng sử dụng (is_active = false, merged_into = hồ sơ được giữ), nếu không thì gắn hồ sơ thô của bên kia vào hồ sơ được giữ; chuyển cặp sang Gộp kèm hồ sơ gốc, người quyết định, thời điểm, lý do; sau đó gọi UC7 đo lại chỉ số mức độ sạch.
10. Hệ thống báo "Đã gộp" và quay lại danh sách. Kết thúc.

### Luồng ngoại lệ (đánh số theo bước):

**3a.** Nhân viên chọn Giữ riêng. Riêng cặp EXACT_PHONE: hai hồ sơ cùng số không thể cùng hiệu lực (QT-01) nên hệ thống yêu cầu nhập một số điện thoại hợp lệ khác cho một hồ sơ; nếu không có, từ chối Giữ riêng và quay lại bước 3 (dữ liệu mẫu có 4 nhóm như vậy). Khi lưu, hệ thống khóa cặp và kiểm tra cặp vẫn Chờ xử lý (nếu không → 8a), chuyển cặp sang

Giữ riêng, ghi người quyết định, thời điểm, lý do, không đề xuất lại cặp này (QL7-05) và gọi UC7 đo lại chỉ số; kết thúc thành công.

**3b.** Nhân viên chọn Để sau: cặp giữ trạng thái Chờ xử lý; quay lại danh sách.

**5a.** Hai hồ sơ có số điện thoại khác nhau: hệ thống yêu cầu chọn số chính (QL7-07); tiếp tục bước 6.

**8a.** Cặp đã được người khác xử lý trong lúc đang xem: hệ thống báo "Cặp này đã được xử lý", làm mới danh sách và quay lại bước 1.

**8b.** Số điện thoại sau gộp trùng với một hồ sơ thứ ba đang hiệu lực: hệ thống từ chối gộp, hiển thị hồ sơ thứ ba và gợi ý xử lý cặp liên quan trước; quay lại bước 1.

**9a.** Lỗi ghi CSDL: hệ thống hoàn tác toàn bộ giao dịch (ROLLBACK) và báo lỗi; cặp vẫn Chờ xử lý; quay lại bước 1.

*Nơi hiển thị thông báo của từng luồng ngoại lệ: vùng thông báo của màn hình K4 (Hình 5.4).*

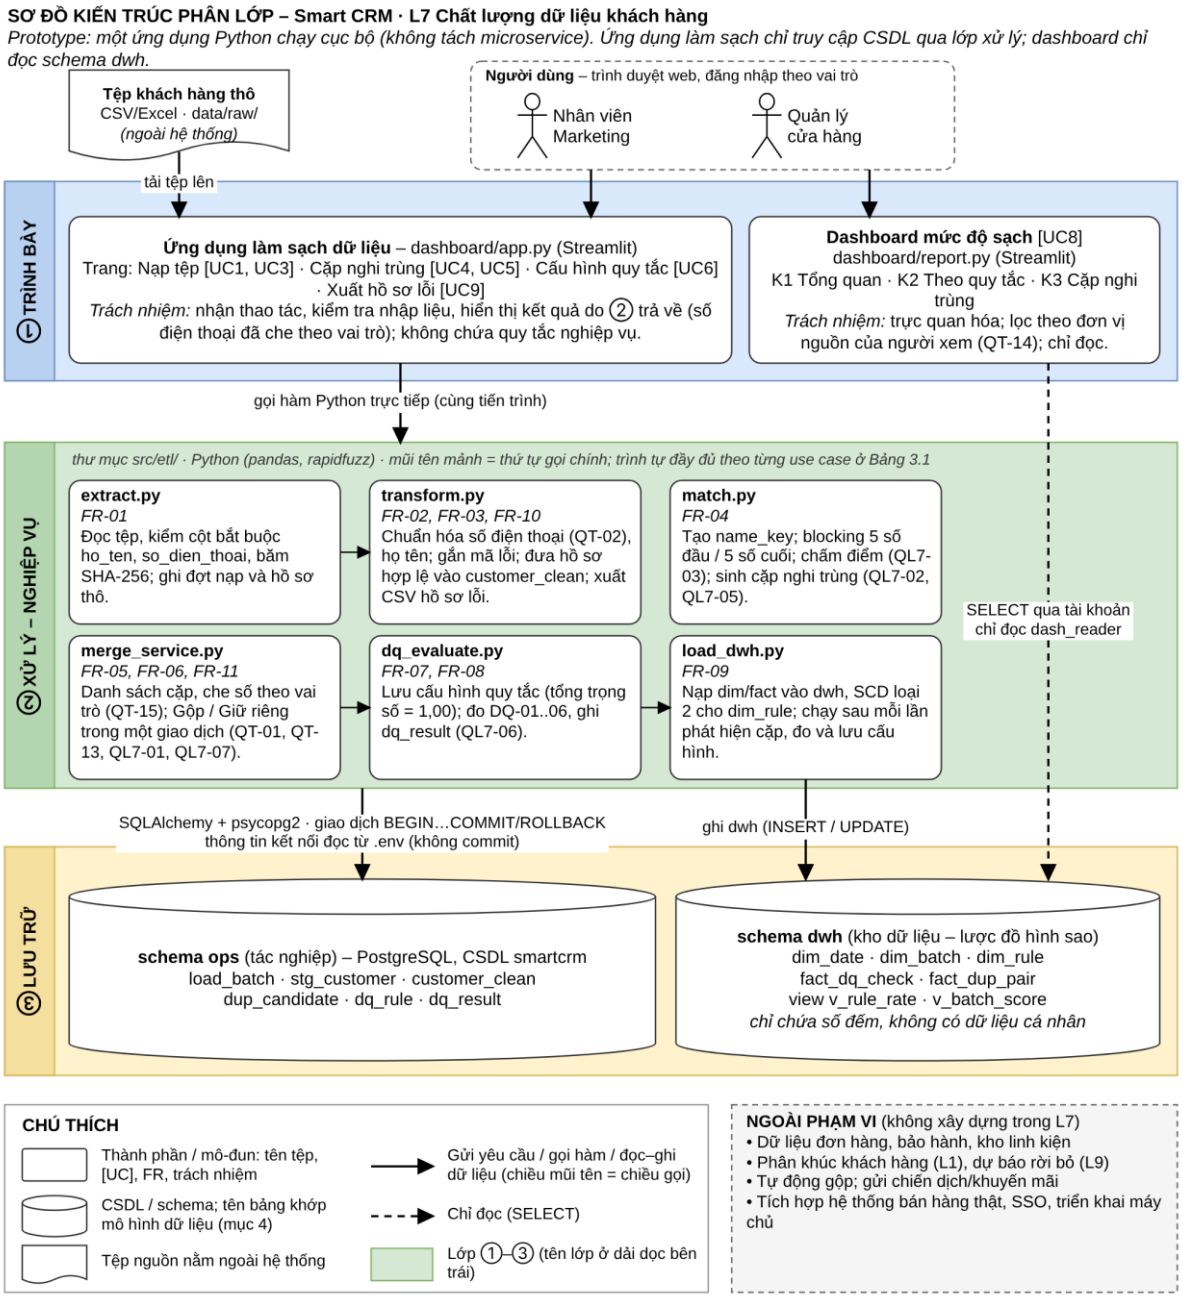
# MỤC 3 – THIẾT KẾ KIẾN TRÚC

## 3.1. Sơ đồ kiến trúc

Hình 3.1 là kiến trúc ba lớp trong một ứng dụng Python chạy cục bộ. Lớp ①chỉ nhận thao tác và hiển thị dữ liệu do lớp ②trả về (số điện thoại đã được che theo vai trò); riêng dashboard đọc thẳng kho qua tài khoản chỉ đọc và lọc theo đơn vị nguồn của người xem (QT-14). Lớp ②chứa toàn bộ quy tắc làm sạch, so khớp, gộp và đo; mỗi mô-đun ứng với một bước xử lý và một nhóm FR (trùng với thư mục src/etl/ của repo track DA); lớp ③là PostgreSQL với schema ops cho dữ liệu tác nghiệp và schema dwh cho kho dữ liệu hình sao. Tên 11 bảng ở lớp ③trùng khớp với mô hình dữ liệu ở mục 4.

**Bảng 3.1 – Cách các phần trao đổi với nhau**

| Giữa | Cách trao đổi |
|---|---|
| **Người dùng ↔ ①Trình bày** | Trình duyệt, HTTP trên localhost (Streamlit). |
| **①→ ②Xử lý** | Gọi hàm Python trực tiếp trong cùng tiến trình; không dùng REST API vì prototype chỉ có một luồng và một ứng dụng. |
| **②↔ ③schema ops** | SQLAlchemy + psycopg2; mọi thao tác ghi nằm trong giao dịch BEGIN…COMMIT/ROLLBACK; thông tin kết nối đọc từ .env (không commit). |
| **②→ ③schema dwh** | load_dwh.py chép từ ops sang dwh bằng INSERT…SELECT (UPDATE khi đóng phiên bản dim_rule, cập nhật trạng thái fact_dup_pair) sau mỗi lần phát hiện cặp (UC3), mỗi lần đo (UC7) và mỗi lần lưu cấu hình quy tắc (UC6). |
| **Dashboard → schema dwh** | Chỉ SELECT, qua tài khoản dash_reader chỉ có quyền đọc schema dwh; không đọc schema ops. |
| **Thứ tự gọi trong ②theo use case** | UC1: extract → transform → dq_evaluate → load_dwh; UC3: match → load_dwh; UC4, UC5: merge_service → dq_evaluate → load_dwh; UC6: dq_evaluate (lưu cấu hình) → load_dwh; UC9: transform (xuất CSV hồ sơ lỗi). |




*Hình 3.1 – Sơ đồ kiến trúc phân lớp (file gốc docs/architecture.drawio)*

## 3.2. Lập luận lựa chọn kiến trúc (gắn với yêu cầu phi chức năng)

**(1)** Vì **NFR-01** yêu cầu phát hiện cặp nghi trùng trên 8.000 hồ sơ trong ≤ 120 giây, tôi chọn xử lý theo lô bằng mô-đun Python match.py với blocking chỉ so sánh hai hồ sơ cùng 5 số đầu hoặc cùng 5 số cuối của số điện thoại chuẩn hóa, đánh đổi là bỏ sót các cặp có số điện thoại sai ở cả nửa đầu lẫn nửa cuối (ví dụ sai 2 chữ số nằm ở hai nửa), nên recall phải được theo dõi bằng NFR-03.

*Căn cứ đo trên mẫu 8.000 dòng (7.506 hồ sơ có số): so toàn bộ cần 28.166.265 cặp, blocking còn 11.858 cặp (0,042%) và vẫn chứa đủ 1.501 cặp hồ sơ cùng số điện thoại (mọi cặp trong nhóm; QL7-02 chỉ giữ $k - 1 = 1.347$ cặp); số sai đúng 1 chữ số luôn còn chung nửa đầu hoặc nửa cuối nên vẫn được so.*

**(2)** Vì **NFR-06** yêu cầu mỗi khung dashboard tải xong ≤ 5 giây với ≤ 24 đợt nạp, tôi chọn tách một lớp kho dữ liệu riêng (schema dwh, lược đồ hình sao chỉ chứa số đếm theo đợt nạp và quy tắc) để dashboard chỉ đọc kho qua tài khoản chỉ đọc thay vì tính lại từ hồ sơ thô, đánh

đổi là phải viết và bảo trì thêm bước nạp kho load_dwh.py cùng 5 bảng, và dashboard chỉ thấy kết quả sau lần nạp kho kế tiếp.

*Căn cứ: mỗi lần đo chỉ thêm 6 dòng số đếm vào fact_dq_check, nên dashboard không phải chạy lại chuẩn hóa, so khớp mẫu và đếm trùng trên hàng nghìn hồ sơ thô mỗi lần mở; kho không chứa họ tên, số điện thoại nên dashboard không thể làm lộ dữ liệu cá nhân (hỗ trợ NFR-07).*

**(3)** Vì **NFR-05** yêu cầu nạp lại cùng tệp với cùng cấu hình cho kết quả giống 100% và chỉ số của lần đo đã có không đổi khi cấu hình thay đổi, tôi chọn giữ nguyên giá trị thô (*_raw) trong stg_customer, làm mọi bước xử lý tất định (trích mẫu đặt seed = 42) và lưu lịch sử quy tắc ở dim_rule theo SCD loại 2 để mỗi lần đo gắn đúng phiên bản trọng số đang hiệu lực, đánh đổi là mỗi hồ sơ chiếm gần gấp đôi dung lượng (cột thô và cột chuẩn hóa), bước nạp kho phải tra phiên bản quy tắc theo khoảng hiệu lực valid_from – valid_to và dim_rule thêm khoảng 6 dòng mỗi lần lưu cấu hình.

**(4)** Vì **NFR-04** yêu cầu 100% số điện thoại của hồ sơ đang hiệu lực đúng mẫu ^0\d{9}$, không trùng và 0 hồ sơ bị xóa vật lý, tôi chọn đặt ràng buộc ngay ở lớp lưu trữ (CHECK theo mẫu, chỉ mục duy nhất từng phần UNIQUE(phone) WHERE is_active, tài khoản ứng dụng không có quyền DELETE) và thực hiện mỗi lần gộp trong một giao dịch, đánh đổi là lớp nghiệp vụ phải bắt lỗi vi phạm ràng buộc để chuyển thành thông báo cho người dùng (luồng 8b, 9a của UC5) và hai người gộp cùng lúc phải chờ khóa dòng của nhau.

# MỤC 4 – MÔ HÌNH DỮ LIỆU THEO CHUYÊN NGÀNH (TRACK DA)

Track DA nộp sơ đồ luồng dữ liệu (data flow) và lược đồ kho dữ liệu. Mô hình gồm hai tầng: tầng tác nghiệp (schema ops, 6 bảng – nguồn OLTP của kho) và kho dữ liệu (schema dwh, 2 bảng fact + 3 bảng dimension). Mọi số liệu nguồn dưới đây được **đo trên customers_raw.csv** bằng script notebooks/profiling_customers.py (seed 42); riêng chỉ số sau khi xử lý hết cặp nghi trùng là ước tính và được ghi rõ.

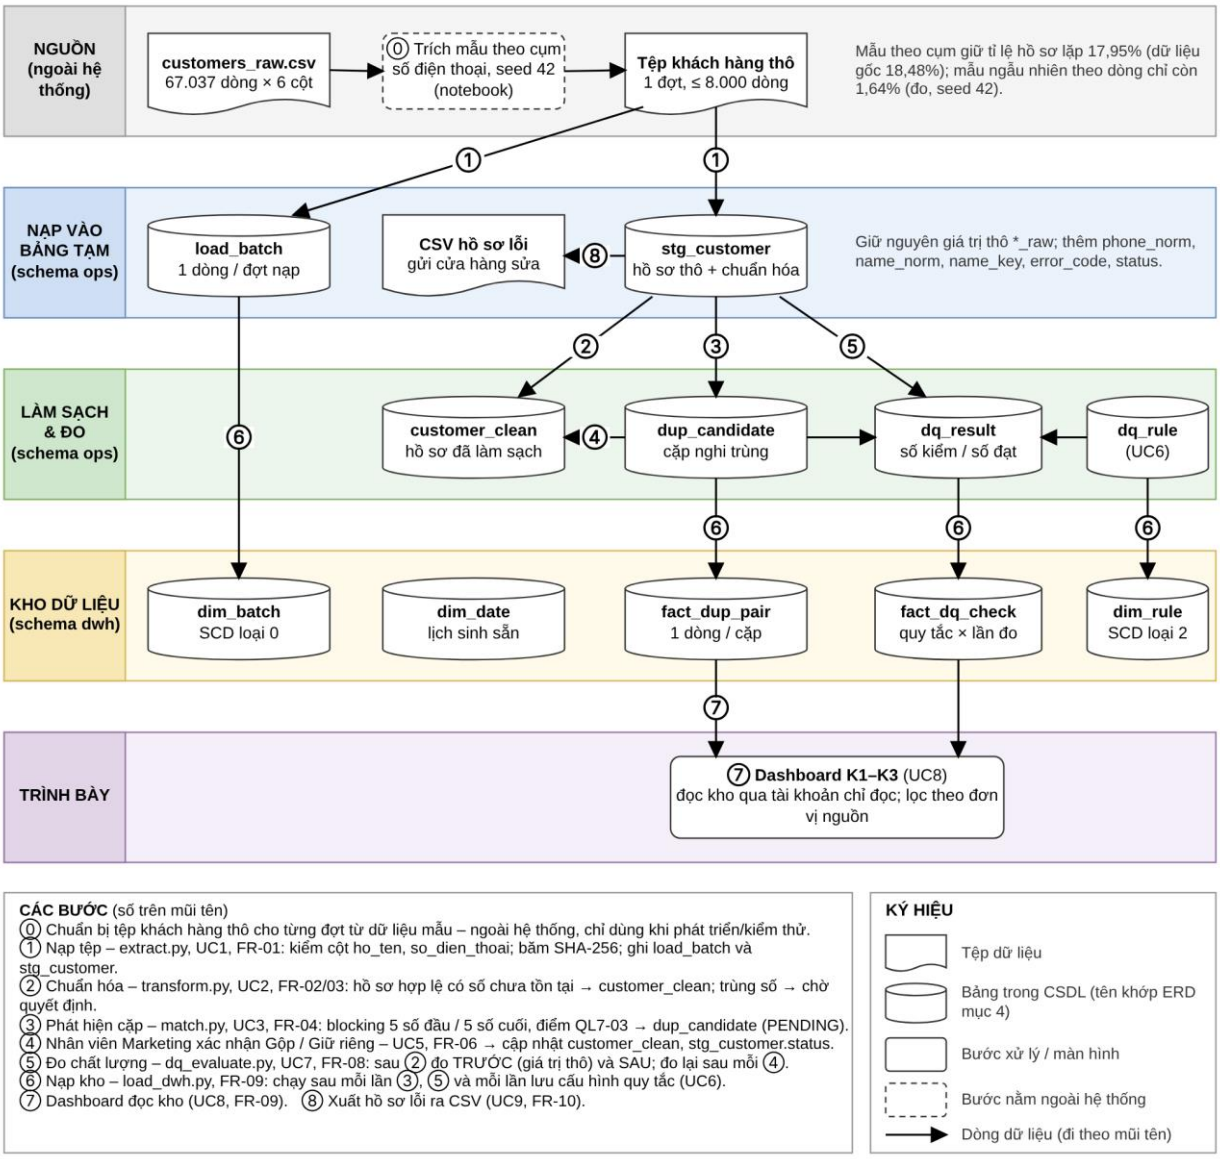
## 4.1. Dữ liệu nguồn (đã đo)

**Bảng 4.1 – Cột của customers_raw.csv (67.037 dòng × 6 cột), ánh xạ vào bảng tạm và số đo**

| Cột nguồn | Ánh xạ vào stg_customer | Ý nghĩa | Tỉ lệ thiếu | Quan sát khi đo |
|---|---|---|---|---|
| **record_id** | source_record_id | Mã dòng trong tệp nguồn | 0% | Duy nhất trong một tệp; không dùng làm khóa vì đổi theo tệp. |
| **ho_ten** | full_name_raw | Họ tên khách | 0% | IN HOA 2.651; chữ thường 1.933; thừa khoảng trắng 1.346; không có chữ số; dài 9–19 ký tự. |
| **so_dien_thoai** | phone_raw | Số điện thoại | 6,17% | 5 dạng: chuẩn 0xxxxxxxxx 65,43%; 84… 9,41%; dấu cách 7,75%; +84… 7,50%; dấu chấm 3,74%. Sau chuẩn hóa: 100% số có giá trị hợp lệ. |
| **email** | email_raw | Thư điện tử | 44,99% | 100% giá trị có mặt đúng mẫu email. |
| **dia_chi** | address_raw | Địa chỉ | 8,98% | Khác nhau giữa các hồ sơ của cùng một khách → không dùng để so khớp. |
| **ngay_tao** | created_raw | Ngày ghi nhận | 0% | 100% dạng yyyy-mm-dd, từ 2024-01-01 đến 2026-08-28 (không lẫn 3 định dạng như giả định ở Buổi 4). |

- **Trùng theo số điện thoại chuẩn hóa:** 51.279 số khác nhau; 10.239 nhóm có từ 2 hồ sơ trở lên (8.854 nhóm 2 hồ sơ, 1.384 nhóm 3, 1 nhóm 4) = 19,97% số khách; 11.625 hồ sơ lặp (18,48% hồ sơ có số) → theo QL7-02 sinh 11.625 cặp EXACT_PHONE.
- **Không tự động gộp được:** 4 nhóm cùng số điện thoại nhưng khác họ tên và ngày ghi nhận (hai người khác nhau) → bằng chứng cho luồng 3a của UC5 và quyết định W1.
- **Họ tên không làm khóa được:** 10.080 trên 10.484 khóa tên không dấu được dùng chung bởi ít nhất 2 số điện thoại khác nhau (nhiều nhất 16 số cho một tên) → họ tên chỉ dùng để chấm điểm trong khối đã chặn theo số điện thoại. Hệ quả là giới hạn đã biết của L7: hai hồ sơ của cùng một khách nhưng số điện thoại khác hẳn nhau (kiểu "ba số khác nhau" của V1) không được phát hiện tự động.
- **Cách trích mẫu:** mẫu ngẫu nhiên theo dòng (6.000 dòng, script Buổi 4, seed 42) chỉ còn 92 hồ sơ lặp (1,64%) vì hai hồ sơ của cùng một khách hiếm khi cùng được chọn → đổi sang trích theo cụm số điện thoại: chọn ngẫu nhiên các số (seed 42), lấy mọi hồ sơ của số đó, cộng thêm tỉ lệ tương ứng hồ sơ thiếu số. Mẫu 8.000 dòng thu được có 17,95% hồ sơ lặp và 6,18% thiếu số – sát dữ liệu gốc.

## 4.2. Sơ đồ luồng dữ liệu từ nguồn đến kho




*Hình 4.1 – Data flow L7: nguồn → bảng tạm → làm sạch và đo → kho dữ liệu → dashboard (file gốc docs/dataflow.drawio)*

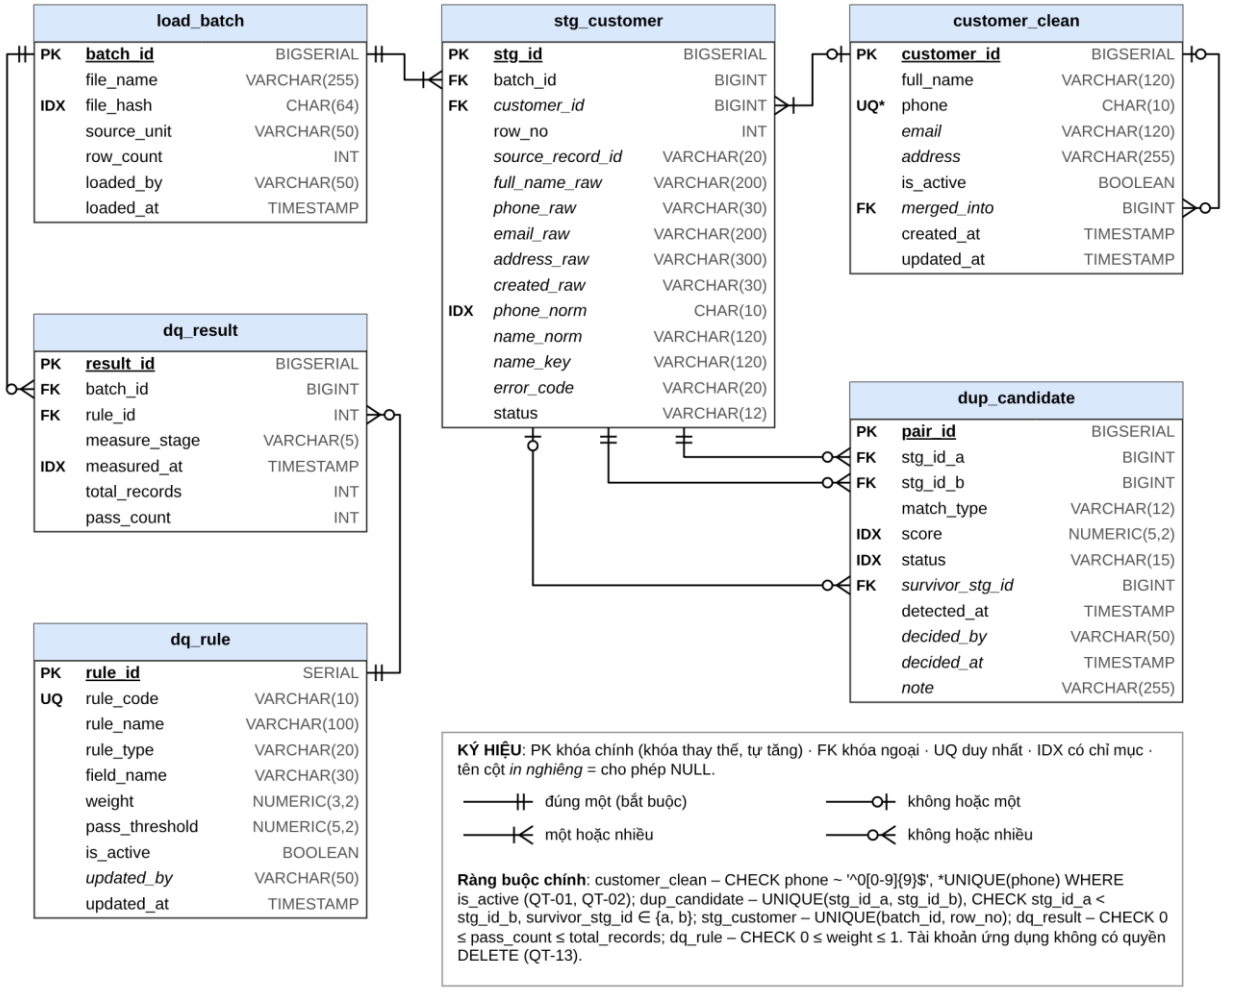
## 4.3. Mô hình dữ liệu tầng tác nghiệp (schema ops)

Tầng tác nghiệp gồm 6 bảng (Hình 4.2): bốn thực thể case study gợi ý cho L7 (stg_customer, customer_clean, dq_rule, dq_result) và hai bảng bổ sung load_batch (đợt nạp), dup_candidate (cặp nghi trùng). Đây là nguồn OLTP của kho dữ liệu; ý nghĩa từng cột ở Phụ lục A. Trước khi chốt mô hình, tôi rà soát năm lỗi ERD theo bước 5 của slide Buổi 6:

**Bảng 4.2 – Soi năm lỗi ERD trên tầng tác nghiệp**

| Lỗi cần soi | Kết quả và cách xử lý |
|---|---|
| **Bảng cô lập** | Không có: 6/6 bảng nối với nhau bằng 8 khóa ngoại (stg_customer.batch_id, stg_customer.customer_id, customer_clean.merged_into, dup_candidate.stg_id_a, stg_id_b, survivor_stg_id, dq_result.batch_id, dq_result.rule_id). |
| **Thiếu bảng lịch sử** | Đã có: quyết định Gộp/Giữ riêng lưu ở dup_candidate (decided_by, decided_at, note); mỗi lần đo là một dòng mới ở dq_result; hồ sơ bị gộp giữ lại với is_active = false và merged_into; lịch sử cấu hình quy tắc lưu ở dim_rule (SCD loại 2). |

| Lỗi cần soi | Kết quả và cách xử lý |
|---|---|
| **Lưu giá trị tính được** | Đã sửa: bỏ pass_rate, weighted_score và "dòng tổng" (rule_id NULL) khỏi dq_result; bỏ phone_sim, name_sim, batch_id khỏi dup_candidate. Ngoại lệ có chủ đích: phone_norm, name_norm, name_key là kết quả bước chuẩn hóa, cần chỉ mục cho so khớp và ràng buộc duy nhất; score là bằng chứng tại thời điểm quyết định (NFR-08); row_count là tổng kiểm soát số dòng đọc từ tệp. |
| **Thiếu chỉ mục** | Đã thêm: stg_customer(batch_id), stg_customer(phone_norm), load_batch(file_hash), dup_candidate(status, score DESC) cho danh sách UC4 (FR-05), dq_result(batch_id, measured_at), UNIQUE(phone) WHERE is_active trên customer_clean. |
| **Khóa nghiệp vụ làm khóa chính** | Không: mọi khóa chính là khóa thay thế tự tăng; khóa nghiệp vụ (phone, rule_code, file_hash, (batch_id, row_no), (stg_id_a, stg_id_b)) chỉ là UNIQUE hoặc chỉ mục. |




*Hình 4.2 – ERD tầng tác nghiệp, 6 bảng, ký hiệu chân chim (file gốc docs/erd.drawio, trang 1)*

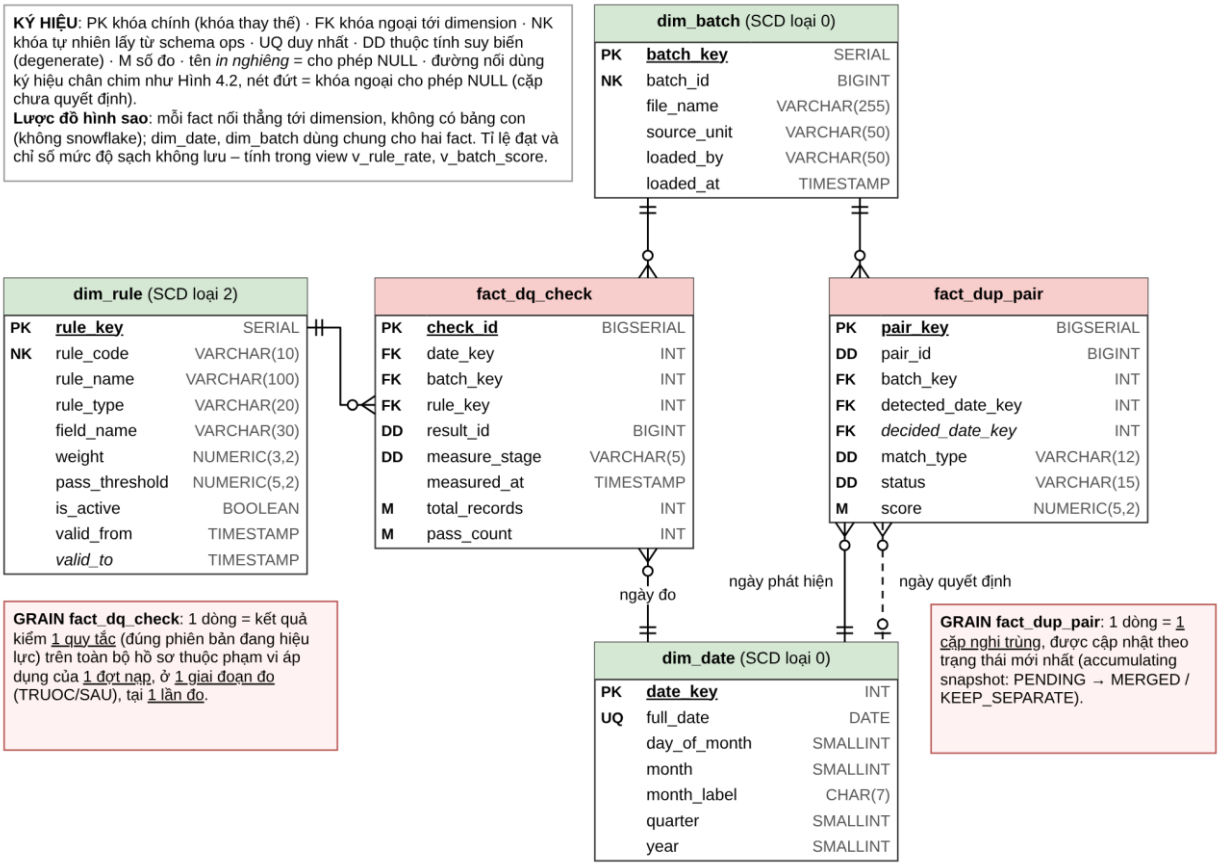
## 4.4. Lược đồ kho dữ liệu (schema dwh)

Thiết kế theo bốn bước: (1) quy trình nghiệp vụ cần đo – kiểm tra chất lượng từng đợt nạp và xử lý cặp nghi trùng; (2) chốt GRAIN cho từng bảng fact (Bảng 4.3); (3) chọn dimension dùng chung: dim_date, dim_batch, dim_rule; (4) chọn số đo: total_records, pass_count ở fact_dq_check, số cặp và score ở fact_dup_pair. Lược đồ ở Hình 4.3; kiểu dữ liệu và ý nghĩa từng cột ở Bảng 4.4.

**Bảng 4.3 – GRAIN của bảng fact (một dòng đại diện cho cái gì)**

| Bảng fact | GRAIN |
|---|---|
| **fact_dq_check** | 1 dòng = kết quả kiểm **1 quy tắc** (đúng phiên bản đang hiệu lực) trên toàn bộ hồ sơ thuộc phạm vi áp dụng của **1 đợt nạp**, ở **1 giai đoạn đo** (TRUOC hoặc SAU), tại **1 lần đo**. Mỗi lần đo sinh 6 dòng (6 quy tắc đang bật). |
| **fact_dup_pair** | 1 dòng = **1 cặp nghi trùng**, được cập nhật theo trạng thái mới nhất (accumulating snapshot: Chờ xử lý → Gộp hoặc Giữ riêng). |

**Tính cộng được:** total_records và pass_count cộng được qua các đợt nạp của cùng một quy tắc và giai đoạn; không cộng qua các quy tắc (một hồ sơ được kiểm bởi nhiều quy tắc) và không cộng qua nhiều lần đo của cùng một đợt (báo cáo lấy lần đo mới nhất). Ở fact_dup_pair, số dòng (số cặp) cộng được theo mọi chiều; score chỉ lấy trung bình hoặc chia khoảng.




*Hình 4.3 – Lược đồ hình sao: 2 bảng fact dùng chung dim_date, dim_batch; dim_rule là SCD loại 2 (file gốc docs/erd.drawio, trang 2)*

**Bảng 4.4 – Từ điển dữ liệu kho (kiểu dữ liệu và ý nghĩa từng cột)**

| Cột | Kiểu | Ràng buộc | Ý nghĩa / nguồn |
|---|---|---|---|
| **dim_date** – dimension ngày (SCD loại 0) – 1 dòng = 1 ngày | | | |
| date_key | INT | PK | Khóa ngày dạng yyyymmdd (ví dụ 20261009). |
| full_date | DATE | NOT NULL, UNIQUE | Ngày dương lịch; sinh sẵn 01/01/2024 – 31/12/2027 (1.461 dòng). |
| day_of_month | SMALLINT | 1–31 | Ngày trong tháng. |
| month | SMALLINT | 1–12 | Tháng – gom nhóm theo tháng. |
| month_label | CHAR(7) | NOT NULL | Nhãn tháng dạng MM/YYYY trên trục biểu đồ. |
| quarter | SMALLINT | 1–4 | Quý. |
| year | SMALLINT | NOT NULL | Năm. |
| **dim_batch** – dimension đợt nạp (SCD loại 0) – 1 dòng = 1 đợt nạp | | | |
| batch_key | SERIAL | PK | Khóa thay thế của đợt nạp trong kho. |
| batch_id | BIGINT | NOT NULL, UNIQUE | Khóa tự nhiên = ops.load_batch.batch_id. |
| file_name | VARCHAR(255) | NOT NULL | Tên tệp khách hàng thô của đợt. |
| source_unit | VARCHAR(50) | NOT NULL | Đơn vị nguồn – bộ lọc theo quyền xem (QT-14). |
| loaded_by | VARCHAR(50) | NOT NULL | Người nạp. |
| loaded_at | TIMESTAMP | NOT NULL | Thời điểm nạp – cột Ngày nạp ở K1. |
| **dim_rule** – dimension quy tắc chất lượng (SCD loại 2) – 1 dòng = 1 phiên bản của 1 quy tắc | | | |
| rule_key | SERIAL | PK | Khóa thay thế; mỗi phiên bản quy tắc một khóa. |
| rule_code | VARCHAR(10) | NOT NULL; UNIQUE(rule_code, valid_from) | Khóa tự nhiên DQ-01 … DQ-06. |

| Cột | Kiểu | Ràng buộc | Ý nghĩa / nguồn |
|---|---|---|---|
| rule_name | VARCHAR(100) | NOT NULL | Tên quy tắc. |
| rule_type | VARCHAR(20) | NOT NULL | COMPLETENESS / VALIDITY / UNIQUENESS – bộ lọc ở K2. |
| field_name | VARCHAR(30) | NOT NULL | Trường dữ liệu được kiểm. |
| weight | NUMERIC(3,2) | NOT NULL, 0–1 | Trọng số của phiên bản. |
| pass_threshold | NUMERIC(5,2) | NOT NULL, 0–100 | Ngưỡng đạt (%) của phiên bản. |
| is_active | BOOLEAN | NOT NULL | Quy tắc bật/tắt trong phiên bản. |
| valid_from | TIMESTAMP | NOT NULL | Bắt đầu hiệu lực (= ops.dq_rule.updated_at). |
| valid_to | TIMESTAMP | NULL được | Hết hiệu lực; NULL = phiên bản hiện hành. |
| **fact_dq_check** – bảng fact kết quả đo – GRAIN ở Bảng 4.3 | | | |
| check_id | BIGSERIAL | PK | Khóa thay thế. |
| date_key | INT | FK → dim_date, NOT NULL | Ngày đo (lấy từ measured_at). |
| batch_key | INT | FK → dim_batch, NOT NULL | Đợt nạp được đo. |
| rule_key | INT | FK → dim_rule, NOT NULL | Phiên bản quy tắc có valid_from ≤ measured_at < valid_to. |
| result_id | BIGINT | NOT NULL, UNIQUE | Thuộc tính suy biến = ops.dq_result.result_id; giúp nạp lại không sinh trùng (NFR-05). |
| measure_stage | VARCHAR(5) | NOT NULL; TRUOC/SAU | Giai đoạn đo – thuộc tính suy biến. |
| measured_at | TIMESTAMP | NOT NULL | Thời điểm lần đo – chọn lần đo mới nhất. |
| total_records | INT | NOT NULL, ≥ 0 | Số đo: số hồ sơ thuộc phạm vi áp dụng (mẫu số). |
| pass_count | INT | NOT NULL, ≤ total_records | Số đo: số hồ sơ đạt quy tắc. |
| **fact_dup_pair** – bảng fact cặp nghi trùng – GRAIN ở Bảng 4.3 | | | |
| pair_key | BIGSERIAL | PK | Khóa thay thế. |
| pair_id | BIGINT | NOT NULL, UNIQUE | Thuộc tính suy biến = ops.dup_candidate.pair_id (khóa để cập nhật). |
| batch_key | INT | FK → dim_batch, NOT NULL | Đợt nạp của hồ sơ nạp sau trong cặp (stg_id_b). |
| detected_date_key | INT | FK → dim_date, NOT NULL | Ngày phát hiện cặp (vai trò 1 của dim_date). |
| decided_date_key | INT | FK → dim_date, NULL được | Ngày quyết định (vai trò 2); NULL khi còn Chờ xử lý. |
| match_type | VARCHAR(12) | NOT NULL | EXACT_PHONE / FUZZY – thuộc tính suy biến. |
| status | VARCHAR(15) | NOT NULL | PENDING / MERGED / KEEP_SEPARATE – cập nhật khi có quyết định. |
| score | NUMERIC(5,2) | NOT NULL, 0–100 | Số đo: điểm tương đồng (lấy trung bình hoặc chia khoảng, không cộng). |

**Bảng 4.5 – Loại SCD cho từng dimension**

| Dimension | Thuộc tính thay đổi theo thời gian? | Loại SCD | Lý do |
|---|---|---|---|
| **dim_rule** | Có: rule_name, rule_type, field_name, weight, pass_threshold, is_active đổi khi Quản lý cửa hàng lưu cấu hình (UC6, FR-07). | Loại 2 – thêm dòng mới với valid_from/valid_to, giữ dòng cũ. | Lần đo cũ phải được tính bằng trọng số đang hiệu lực lúc đo; ghi đè (loại 1) sẽ làm chỉ số mức độ sạch và đường xu hướng ở K1 bị tính lại hồi tố, vi phạm NFR-05. |
| **dim_batch** | Không: tên tệp, đơn vị nguồn, người nạp, thời điểm cố định sau khi nạp. | Loại 0 – không cập nhật. | Đợt nạp là sự kiện đã xảy ra; muốn sửa thì nạp đợt mới. |
| **dim_date** | Không. | Loại 0. | Lịch tĩnh, sinh sẵn. |

Chọn **lược đồ hình sao (star)**, không chọn bông tuyết (snowflake), vì ba lý do:

(1) Ba dimension đều nhỏ – dim_rule khoảng 6 dòng cho mỗi phiên bản cấu hình, dim_batch tối đa 24 đợt trong phạm vi NFR-06, dim_date 1.461 dòng – nên tách tiếp (đơn vị nguồn, loại quy tắc, tháng/quý ra bảng riêng) chỉ tiết kiệm vài trăm byte nhưng mỗi biểu đồ phải nối thêm 1–2 bảng.

(2) Mỗi biểu đồ ở K1–K3 chỉ cần nối fact với tối đa 3 dimension một bước, dễ viết truy vấn cho dashboard Streamlit và giữ thời gian tải ≤ 5 giây (NFR-06).

(3) Hai fact dùng chung dim_date và dim_batch (conformed dimension) nên một bộ lọc ngày – đơn vị nguồn – đợt nạp áp dụng được cho cả K1, K2, K3; tổng thể là hai ngôi sao dùng chung dimension, mỗi ngôi sao vẫn phẳng.

**Bảng 4.6 – Chỉ số tính trong view (không lưu vào bảng)**

| View / truy vấn | Mức chi tiết | Công thức | Dùng ở |
|---|---|---|---|
| **v_rule_rate** | 1 dòng / 1 dòng fact_dq_check | pass_rate NUMERIC(5,4) = COALESCE(pass_count::NUMERIC / NULLIF(total_records, 0), 1); fail_count INT = total_records − pass_count; lost_points NUMERIC(5,2) = weight × (1 − pass_rate) × 100; is_pass BOOLEAN = pass_rate × 100 ≥ pass_threshold. | K2 |
| **v_batch_score** | 1 dòng / (đợt nạp, giai đoạn, lần đo) | clean_index NUMERIC(5,2) = Σ weight × pass_rate × 100 trên các quy tắc is_active; grade VARCHAR(15) = Tốt / Chấp nhận được / Kém (QL7-06); is_latest BOOLEAN = lần đo có measured_at lớn nhất theo (đợt, giai đoạn). | K1 |
| **Tỉ lệ gộp (truy vấn của K3)** | theo khoảng điểm hoặc đợt | merge_rate NUMERIC(5,4) = MERGED / (MERGED + KEEP_SEPARATE); khoảng điểm < 85, 85 – <90, 90 – <95, ≥ 95 tính từ score. | K3 |

### Quy tắc nạp kho (bước ⑥ load_dwh.py):

- Thời điểm chạy: sau mỗi lần phát hiện cặp (UC3), mỗi lần đo (UC7) và mỗi lần lưu cấu hình quy tắc (UC6); thêm dòng mới bằng INSERT…SELECT, dùng UPDATE khi đóng phiên bản dim_rule và khi cập nhật trạng thái fact_dup_pair.
- dim_rule: so sánh ops.dq_rule với phiên bản hiện hành theo rule_code; khác thì đóng phiên bản cũ (valid_to = updated_at) và thêm phiên bản mới (SCD loại 2).
- dim_batch: thêm các đợt nạp chưa có (theo batch_id); không cập nhật dòng cũ (loại 0). dim_date sinh sẵn một lần.
- fact_dq_check: thêm các dòng ops.dq_result chưa có (theo result_id); rule_key = phiên bản có valid_from ≤ measured_at < valid_to (valid_to NULL coi như vô hạn).
- fact_dup_pair: thêm cặp mới; với cặp đã có (theo pair_id) chỉ cập nhật status và decided_date_key khi có quyết định.

## 4.5. Bộ quy tắc chất lượng (nội dung dim_rule) và số đo cơ sở

**Bảng 4.7 – Quy tắc DQ-01 … DQ-06 và tỉ lệ đạt đo trên toàn bộ customers_raw.csv**

| Mã | Loại | Kiểm tra | Phạm vi áp dụng (mẫu số) | Trọng số | Ngưỡng đạt | TRƯỚC (đo) | SAU chuẩn hóa (đo) |
|---|---|---|---|---|---|---|---|
| **DQ-01** | COMPLETENESS | Số điện thoại không trống | Mọi hồ sơ của đợt | 0,25 | ≥ 98% | 93,83% | 93,83% |
| **DQ-02** | VALIDITY | Số điện thoại khớp ^0\d{9}$ (TRƯỚC: giá trị thô; SAU: phone_norm) | Hồ sơ có số điện thoại | 0,25 | ≥ 95% | 69,73% | 100% |
| **DQ-03** | COMPLETENESS | Họ tên không trống | Mọi hồ sơ của đợt | 0,15 | ≥ 99% | 100% | 100% |
| **DQ-04** | VALIDITY | Họ tên 2–120 ký tự, không chứa chữ số | Hồ sơ có họ tên | 0,10 | ≥ 97% | 100% | 100% |
| **DQ-05** | UNIQUENESS | Số điện thoại không trùng (so theo phone_norm ở cả hai giai đoạn): trong mỗi nhóm cùng số, hồ sơ nạp sớm nhất đạt; hồ sơ khác chỉ đạt khi cặp của nó đã Gộp hoặc Giữ riêng | Hồ sơ có số hợp lệ | 0,20 | ≥ 98% | 81,52% | 81,52% → 100% khi xử lý hết cặp |

| Mã | Loại | Kiểm tra | Phạm vi áp dụng (mẫu số) | Trọng số | Ngưỡng đạt | TRƯỚC (đo) | SAU chuẩn hóa (đo) |
|---|---|---|---|---|---|---|---|
| **DQ-06** | VALIDITY | Email đúng mẫu | Hồ sơ có email | 0,05 | ≥ 95% | 100% | 100% |

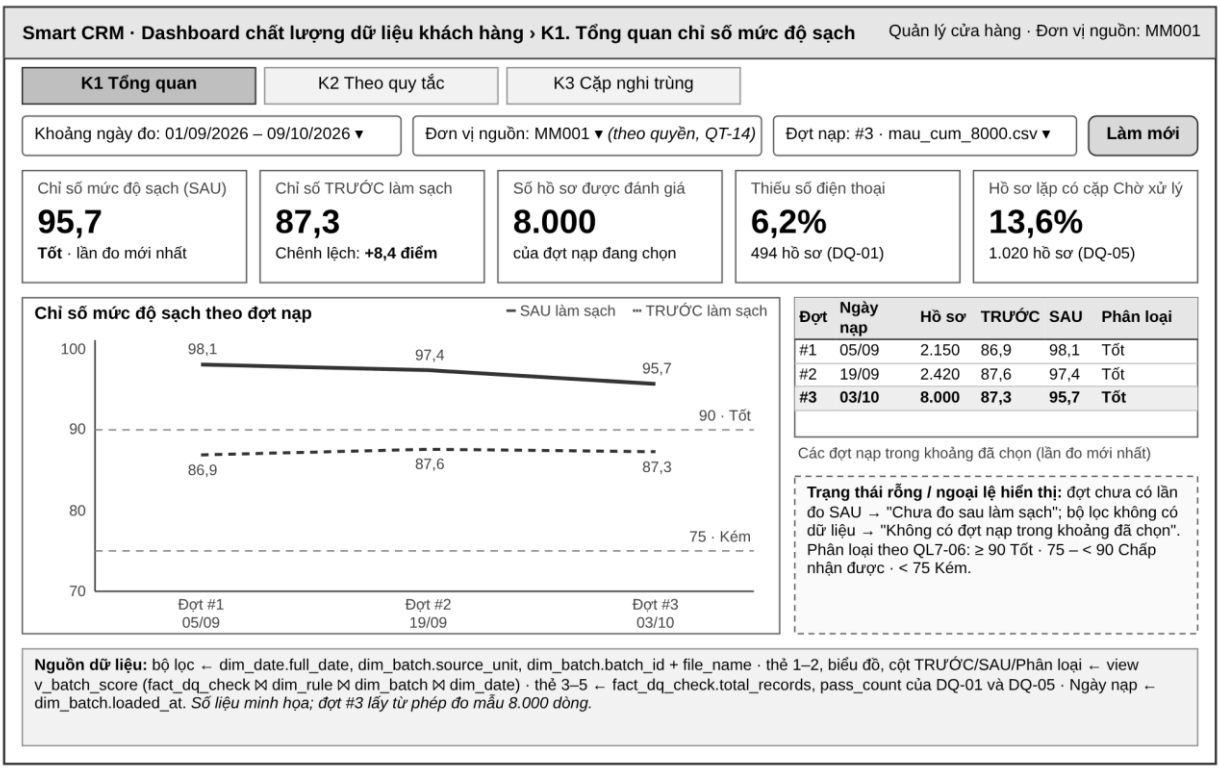
**Bảng 4.8 – Chỉ số mức độ sạch (QL7-06)**

| Thời điểm | Chỉ số mức độ sạch |
|---|---|
| **Chỉ số mức độ sạch TRƯỚC làm sạch (đo)** | 87,20 – Chấp nhận được |
| **SAU chuẩn hóa, chưa có quyết định trùng (đo)** | 94,76 – Tốt (+7,56 điểm) |
| **SAU khi xử lý hết cặp nghi trùng (ước tính)** | 98,46 – Tốt (+11,26 điểm so với TRƯỚC) |
| **Mẫu 8.000 dòng theo cụm (đo; giá trị cuối là ước tính)** | 87,34 → 94,87 → 98,46 (cùng xu hướng) |

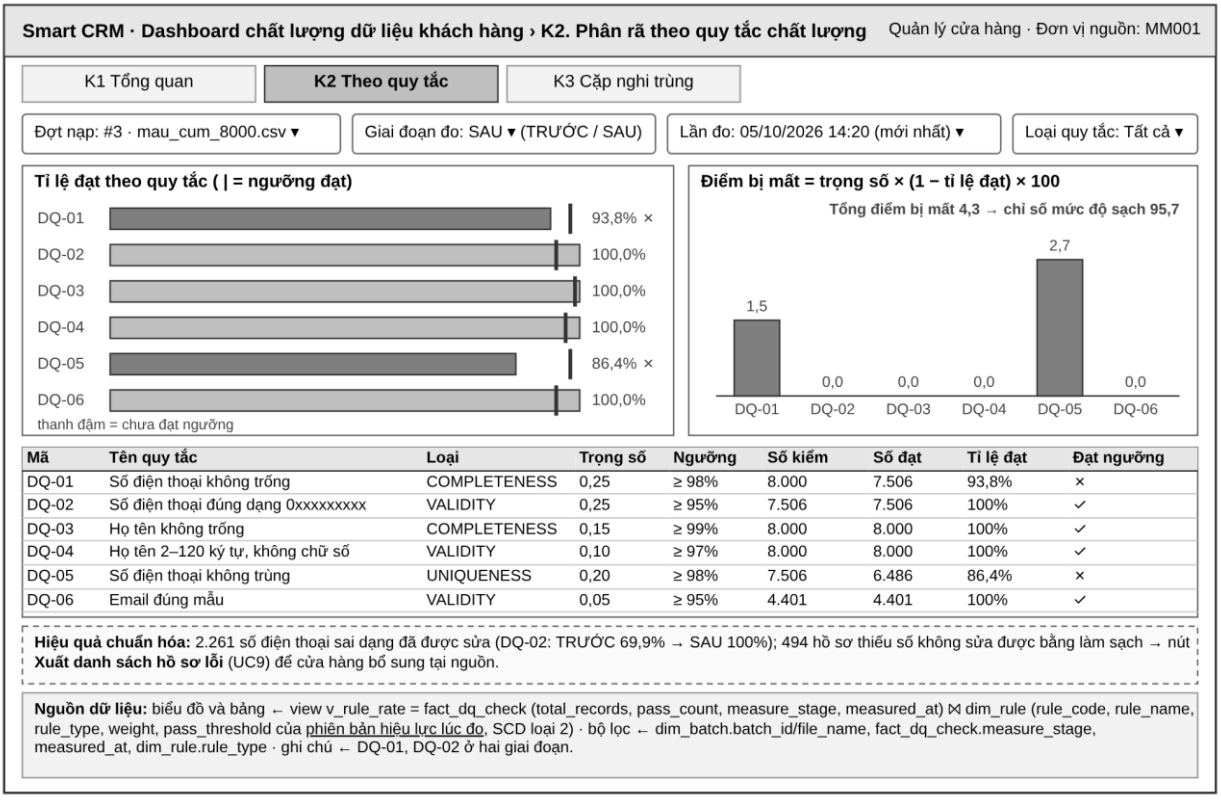
- Mục tiêu đặt ở docs/data-requirements.md: chỉ số SAU ≥ 90 (Tốt) và cao hơn TRƯỚC ít nhất 10 điểm. Chuẩn hóa một mình chỉ tăng 7,56 điểm; mục tiêu chỉ đạt (+11,26) khi Marketing xử lý hết cặp nghi trùng – đó là lý do UC5/US4 là MUST.
- DQ-01 (93,83%) không thể đạt ngưỡng 98% bằng làm sạch vì số điện thoại bị thiếu thật; chỉ sửa được tại nguồn → US7/UC9 xuất danh sách 4.133 hồ sơ lỗi cho cửa hàng.
- DQ-03, DQ-04 đạt 100% trên dữ liệu mẫu nhưng vẫn giữ vì tệp thật của cửa hàng có thể thiếu hoặc ghi sai họ tên.

# MỤC 5 – WIREFRAME

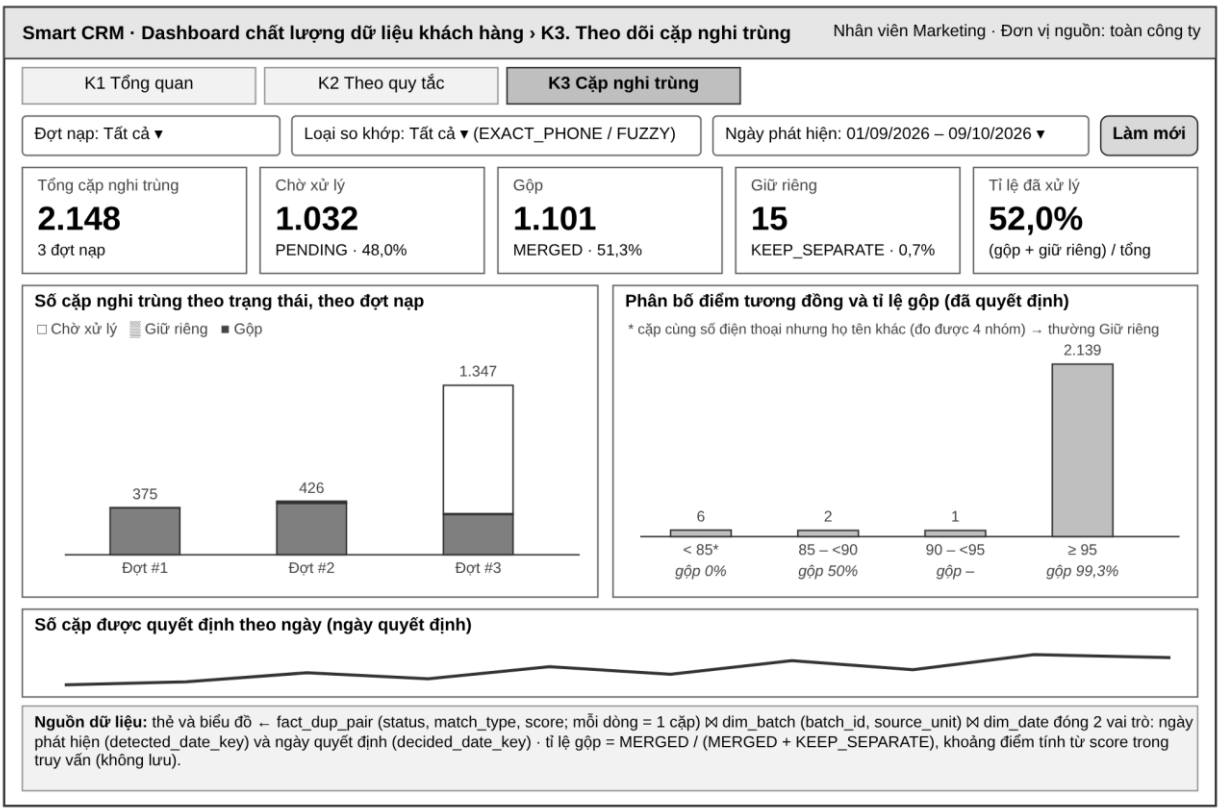
Track DA yêu cầu ba khung dashboard (K1 – K3) gồm bố cục biểu đồ, bộ lọc và chỉ số tổng hợp, kèm nguồn dữ liệu của từng khung (dải "Nguồn dữ liệu" ở cuối mỗi khung). Khung K4 là màn hình tác nghiệp của UC4/UC5, bổ sung để chứng minh mọi luồng ngoại lệ đã đặc tả đều có chỗ hiển thị thông báo (phép kiểm 6). Wireframe đen trắng; nhãn dùng đúng bảng thuật ngữ; số liệu minh họa lấy theo phép đo mẫu 8.000 dòng. File gốc: docs/wireframe.drawio (4 trang), ảnh gộp docs/wireframe.png.



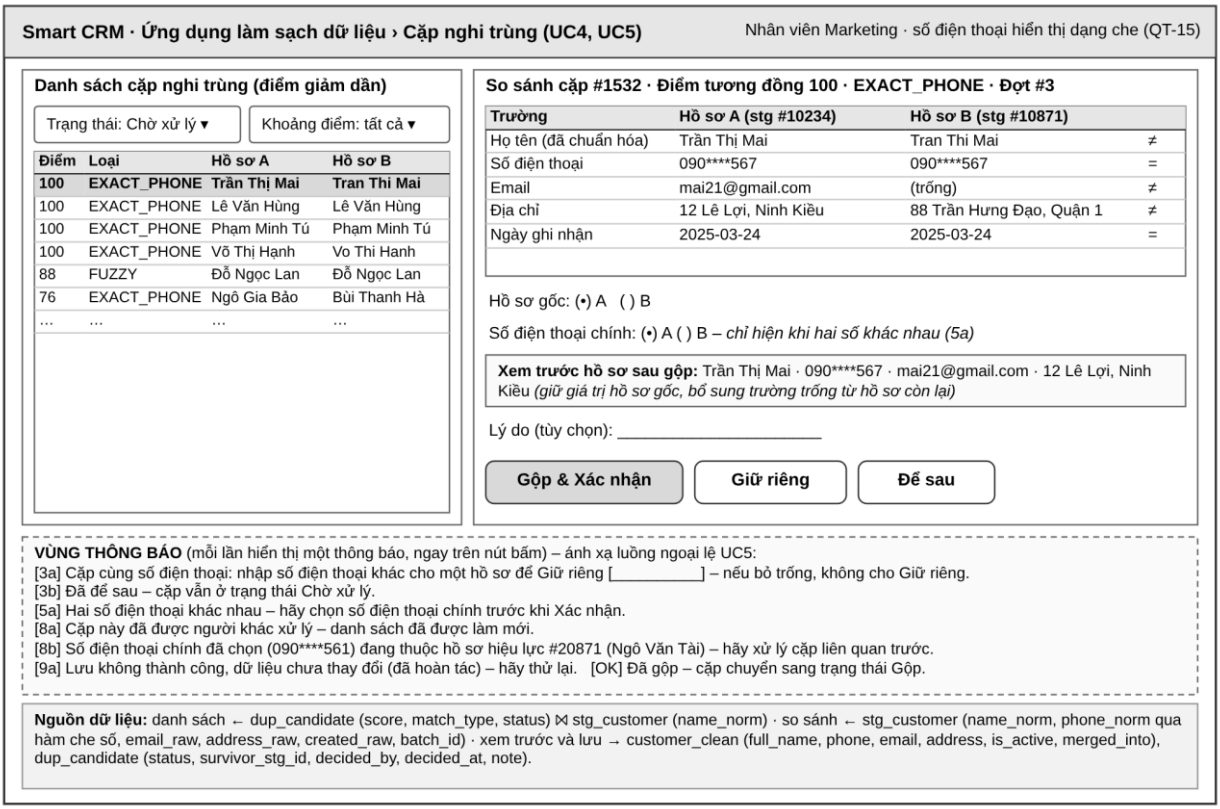

*Hình 5.1 – K1. Tổng quan chỉ số mức độ sạch (UC8)*




*Hình 5.2 – K2. Phân rã theo quy tắc chất lượng (UC8; kết quả UC6, UC7)*




*Hình 5.3 – K3. Theo dõi cặp nghi trùng (UC8; kết quả UC3, UC5)*




*Hình 5.4 – K4. Xác nhận cặp nghi trùng – màn hình tác nghiệp của UC4, UC5*

**Bảng 5.1 – Khung màn hình ↔ use case ↔ trường hiển thị ↔ nguồn dữ liệu**

| Khung | Use case · US · FR | Thành phần hiển thị | Nguồn dữ liệu (bảng.cột) |
|---|---|---|---|
| **K1 – Tổng quan chỉ số mức độ sạch** | UC8 · US1, US6 · FR-01, FR-08, FR-09 | Bộ lọc khoảng ngày, đơn vị nguồn, đợt nạp; 5 thẻ chỉ số; biểu đồ đường TRƯỚC/SAU theo đợt; bảng đợt nạp; thông báo trạng thái rỗng. | dim_date.full_date; dim_batch.source_unit, batch_id, file_name, loaded_at; v_batch_score; fact_dq_check.total_records, pass_count (DQ-01, DQ-05). |
| **K2 – Phân rã theo quy tắc** | UC8 (kết quả UC6, UC7) · US1, US5, US6 · FR-02, FR-07 – FR-09 | Bộ lọc đợt nạp, giai đoạn đo, lần đo, loại quy tắc; thanh tỉ lệ đạt so với ngưỡng; cột điểm bị mất; bảng quy tắc; ghi chú hiệu quả chuẩn hóa. | v_rule_rate = fact_dq_check (total_records, pass_count, measure_stage, measured_at) ⋈ dim_rule (rule_code, rule_name, rule_type, weight, pass_threshold). |
| **K3 – Theo dõi cặp nghi trùng** | UC8 (kết quả UC3, UC5) · US3, US4, US6 · FR-04, FR-06, FR-09 | Bộ lọc đợt nạp, loại so khớp, ngày phát hiện; 5 thẻ trạng thái; cột chồng theo đợt; phân bố điểm và tỉ lệ gộp; xu hướng theo ngày quyết định. | fact_dup_pair.status, match_type, score ⋈dim_batch.batch_id, source_unit ⋈ dim_date qua detected_date_key và decided_date_key (hai vai trò). |
| **K4 – Xác nhận cặp nghi trùng (màn hình tác nghiệp)** | UC4, UC5 · US2, US4 · FR-03, FR-05, FR-06, FR-11 | Danh sách cặp; bảng so sánh hai hồ sơ; chọn hồ sơ gốc và số chính; xem trước; nút Gộp / Giữ riêng / Để sau; vùng thông báo 3a – 9a. | dup_candidate.score, match_type, status, survivor_stg_id, decided_by, decided_at, note; stg_customer.name_norm, phone_norm (che số), email_raw, address_raw, created_raw, batch_id; customer_clean.full_name, phone, email, address, is_active, merged_into. |

Kiểm ngược (phép 4): 11/11 bảng xuất hiện ở ít nhất một khung hoặc báo cáo – load_batch (qua dim_batch, K1), stg_customer (K4, tệp CSV hồ sơ lỗi), customer_clean (K4), dup_candidate (K4; qua fact_dup_pair ở K3), dq_rule (qua dim_rule, K2), dq_result (qua fact_dq_check, K1–K2), dim_date, dim_batch, dim_rule, fact_dq_check, fact_dup_pair (K1–K3).

# PHỤ LỤC A – TỪ ĐIỂN DỮ LIỆU TẦNG TÁC NGHIỆP (SCHEMA ops)

Kiểu dữ liệu theo cú pháp PostgreSQL; khớp từng cột với Hình 4.2.

| Cột | Kiểu | Ràng buộc | Ý nghĩa / nguồn |
|---|---|---|---|
| **load_batch** – đợt nạp – 1 dòng = 1 lần nạp một tệp khách hàng thô | | | |
| batch_id | BIGSERIAL | PK | Mã đợt nạp. |
| file_name | VARCHAR(255) | NOT NULL | Tên tệp khách hàng thô đã nạp. |
| file_hash | CHAR(64) | NOT NULL, INDEX | Giá trị băm SHA-256 của tệp, dùng cảnh báo nạp lại (FR-01). |
| source_unit | VARCHAR(50) | NOT NULL | Đơn vị nguồn (mã cửa hàng/kênh) – căn cứ lọc theo QT-14. |
| row_count | INT | NOT NULL, ≥ 0 | Số dòng đọc được từ tệp – tổng kiểm soát để đối chiếu với số hồ sơ thô đã ghi. |
| loaded_by | VARCHAR(50) | NOT NULL | Tên đăng nhập người nạp. |
| loaded_at | TIMESTAMP | NOT NULL, mặc định now() | Thời điểm nạp. |
| **stg_customer** – bảng tạm – 1 dòng = 1 hồ sơ thô | | | |
| stg_id | BIGSERIAL | PK | Mã hồ sơ thô. |
| batch_id | BIGINT | FK → load_batch, NOT NULL | Đợt nạp chứa hồ sơ. |
| customer_id | BIGINT | FK → customer_clean, NULL được | Hồ sơ đã làm sạch mà hồ sơ thô thuộc về; NULL khi là hồ sơ lỗi hoặc đang chờ quyết định trùng. |
| row_no | INT | NOT NULL; UNIQUE(batch_id, row_no) | Số thứ tự dòng trong tệp. |
| source_record_id | VARCHAR(20) | NULL được | Giá trị cột record_id của tệp nguồn (chỉ để đối chiếu). |
| full_name_raw | VARCHAR(200) | NULL được | Họ tên như trong tệp (cột ho_ten). |
| phone_raw | VARCHAR(30) | NULL được | Số điện thoại như trong tệp (cột so_dien_thoai). |
| email_raw | VARCHAR(200) | NULL được | Email như trong tệp. |
| address_raw | VARCHAR(300) | NULL được | Địa chỉ như trong tệp (cột dia_chi). |
| created_raw | VARCHAR(30) | NULL được | Ngày ghi nhận như trong tệp (cột ngay_tao). |
| phone_norm | CHAR(10) | NULL được, INDEX | Số điện thoại sau chuẩn hóa (QT-02); NULL khi thiếu hoặc không hợp lệ. |
| name_norm | VARCHAR(120) | NULL được | Họ tên sau chuẩn hóa (bỏ khoảng trắng thừa, viết hoa chữ cái đầu). |
| name_key | VARCHAR(120) | NULL được | Họ tên không dấu, chữ thường – khóa so khớp (QL7-03). |
| error_code | VARCHAR(20) | NULL được; MISSING_PHONE / INVALID_PHONE / MISSING_NAME | Mã lỗi chính khiến hồ sơ không vào customer_clean. |
| status | VARCHAR(12) | NOT NULL; LOADED / CLEAN / PENDING_DUP / MERGED / ERROR | Bước xử lý hiện tại của hồ sơ thô. |
| **customer_clean** – hồ sơ đã làm sạch – 1 dòng = 1 hồ sơ (đang hiệu lực hoặc đã ngừng sử dụng) | | | |
| customer_id | BIGSERIAL | PK | Mã hồ sơ đã làm sạch. |
| full_name | VARCHAR(120) | NOT NULL | Họ tên đã chuẩn hóa. |
| phone | CHAR(10) | NOT NULL; CHECK ~ '^0[0-9]{9}$'; UNIQUE WHERE is_active | Số điện thoại chính (QT-01, QT-02). |
| email | VARCHAR(120) | NULL được | Email. |
| address | VARCHAR(255) | NULL được | Địa chỉ liên hệ. |
| is_active | BOOLEAN | NOT NULL, mặc định true | false = ngừng sử dụng, đã được gộp vào hồ sơ khác (QT-13). |
| merged_into | BIGINT | FK → customer_clean, NULL được | Hồ sơ được giữ lại (đang hiệu lực) đã nhận hồ sơ này khi gộp. |
| created_at | TIMESTAMP | NOT NULL | Thời điểm tạo hồ sơ. |
| updated_at | TIMESTAMP | NOT NULL | Thời điểm cập nhật gần nhất. |

| Cột | Kiểu | Ràng buộc | Ý nghĩa / nguồn |
|---|---|---|---|
| **dup_candidate** – cặp nghi trùng – 1 dòng = 1 cặp hồ sơ thô | | | |
| pair_id | BIGSERIAL | PK | Mã cặp nghi trùng. |
| stg_id_a | BIGINT | FK → stg_customer, NOT NULL | Hồ sơ thứ nhất của cặp (hồ sơ nạp sớm hơn). |
| stg_id_b | BIGINT | FK → stg_customer, NOT NULL; UNIQUE(stg_id_a, stg_id_b); CHECK stg_id_a < stg_id_b | Hồ sơ thứ hai của cặp. |
| match_type | VARCHAR(12) | NOT NULL; EXACT_PHONE / FUZZY | Loại so khớp đã tạo ra cặp. |
| score | NUMERIC(5,2) | NOT NULL, 0–100; INDEX(status, score) | Điểm tương đồng lúc phát hiện (QL7-03) – lưu làm bằng chứng quyết định (NFR-08). |
| status | VARCHAR(15) | NOT NULL, mặc định PENDING; PENDING / MERGED / KEEP_SEPARATE | Trạng thái: Chờ xử lý / Gộp / Giữ riêng. |
| survivor_stg_id | BIGINT | FK → stg_customer, NULL được; thuộc {stg_id_a, stg_id_b} | Hồ sơ gốc được chọn khi Gộp. |
| detected_at | TIMESTAMP | NOT NULL | Thời điểm phát hiện cặp. |
| decided_by | VARCHAR(50) | NULL được | Người quyết định Gộp/Giữ riêng. |
| decided_at | TIMESTAMP | NULL được | Thời điểm quyết định. |
| note | VARCHAR(255) | NULL được | Lý do quyết định (tùy chọn). |
| **dq_rule** – quy tắc chất lượng dữ liệu (cấu hình hiện hành) – 1 dòng = 1 quy tắc | | | |
| rule_id | SERIAL | PK | Mã quy tắc. |
| rule_code | VARCHAR(10) | NOT NULL, UNIQUE | Mã nghiệp vụ DQ-01 … DQ-06. |
| rule_name | VARCHAR(100) | NOT NULL | Tên quy tắc. |
| rule_type | VARCHAR(20) | NOT NULL; COMPLETENESS / VALIDITY / UNIQUENESS | Loại tiêu chí chất lượng. |
| field_name | VARCHAR(30) | NOT NULL | Trường được kiểm (phone, full_name, email). |
| weight | NUMERIC(3,2) | NOT NULL, 0–1 | Trọng số trong chỉ số mức độ sạch (tổng các quy tắc đang bật = 1,00). |
| pass_threshold | NUMERIC(5,2) | NOT NULL, 0–100 | Ngưỡng đạt (%) của quy tắc. |
| is_active | BOOLEAN | NOT NULL | Quy tắc đang bật hay tắt. |
| updated_by | VARCHAR(50) | NULL được | Người sửa cấu hình gần nhất (UC6). |
| updated_at | TIMESTAMP | NOT NULL | Thời điểm sửa gần nhất – dùng làm valid_from của phiên bản mới ở dim_rule. |
| **dq_result** – kết quả đo – 1 dòng = 1 quy tắc × 1 đợt nạp × 1 giai đoạn × 1 lần đo | | | |
| result_id | BIGSERIAL | PK | Mã kết quả đo. |
| batch_id | BIGINT | FK → load_batch, NOT NULL | Đợt nạp được đo. |
| rule_id | INT | FK → dq_rule, NOT NULL | Quy tắc được đo. |
| measure_stage | VARCHAR(5) | NOT NULL; TRUOC / SAU | Giai đoạn đo: trước hay sau làm sạch. |
| measured_at | TIMESTAMP | NOT NULL; INDEX(batch_id, measured_at) | Thời điểm của lần đo. |
| total_records | INT | NOT NULL, ≥ 0 | Số hồ sơ thuộc phạm vi áp dụng của quy tắc (mẫu số). |
| pass_count | INT | NOT NULL; 0 ≤ pass_count ≤ total_records | Số hồ sơ đạt quy tắc. |

# PHỤ LỤC B – RÀ SOÁT VÀ NHẬT KÝ THAY ĐỔI SO VỚI BẢN BUỔI 4

Rà soát theo bảng tiêu chí kỹ thuật tối thiểu của BT1 (7 mục chung và các mục riêng của track DA, mở rộng theo slide Buổi 6), sáu phép kiểm nhất quán và năm lỗi ERD. Mọi thay đổi so với hồ sơ Buổi 4 được ghi lại để phục vụ tiêu chí 3 của rubric (nhất quán và tích lũy).

## B.1. Tự kiểm theo bảng tiêu chí kỹ thuật tối thiểu

| Nhóm | Mục kiểm chứng | Kết quả | Minh chứng |
|---|---|---|---|
| Chung | Có đủ 5 đầu mục: SRS, Use Case, kiến trúc, mô hình dữ liệu, wireframe | Đạt | Mục 1 – 5 |
| Chung | Mỗi yêu cầu chức năng truy vết tới ít nhất 1 User Story | Đạt | Bảng 1.7: 11/11 FR có User Story, không ô trống |
| Chung | Mọi sơ đồ có chú thích, đọc được không cần giải thích thêm | Đạt | Hình 2.1, 3.1, 4.1 – 4.3, 5.1 – 5.4 đều có khung ký hiệu hoặc ghi chú nguồn dữ liệu |
| Chung | Thuật ngữ nhất quán giữa SRS và các sơ đồ | Đạt | Bảng 1.1; soát bằng Ctrl+F (B.2, phép 1) |
| Chung | ≥ 3 câu giải thích lựa chọn kiến trúc, gắn NFR và có đánh đổi | Đạt | Mục 3.2: 4 câu (NFR-01, NFR-06, NFR-05, NFR-04) |
| Chung | Mọi yêu cầu phi chức năng có ngưỡng số đo được | Đạt | Bảng 1.5: 8/8 NFR |
| Chung | Có bảng khai báo sử dụng công cụ AI | Đạt | Phụ lục C |
| DA | Có ≥ 1 bảng fact + 2 bảng dimension | Đạt | 2 fact (fact_dq_check, fact_dup_pair) + 3 dimension (dim_date, dim_batch, dim_rule) |
| DA | Mỗi cột ghi rõ kiểu dữ liệu và ý nghĩa | Đạt | Bảng 4.4 (kho dữ liệu); Phụ lục A (tầng tác nghiệp) |
| DA | Phát biểu rõ GRAIN của bảng fact | Đạt | Bảng 4.3; ghi lại trên Hình 4.3 |
| DA | Có sơ đồ data flow từ nguồn đến kho dữ liệu | Đạt | Hình 4.1 |
| DA | Nêu loại SCD cho dimension thay đổi theo thời gian, kèm lý do | Đạt | Bảng 4.5: dim_rule loại 2; dim_batch, dim_date loại 0 |
| DA | Giải thích chọn star hay snowflake và lý do | Đạt | Mục 4.4 – đoạn "Chọn lược đồ hình sao" |

## B.2. Sáu phép kiểm nhất quán và soi lỗi ERD

| Phép kiểm | Phát hiện ở bản Buổi 4 và cách đã sửa |
|---|---|
| **Phép 1 – Thuật ngữ** | Bổ sung các thuật ngữ mới dùng ở mục 3 – 5 (đơn vị nguồn, hồ sơ thô, hồ sơ lỗi, hồ sơ lặp, khóa tên, lần đo, kho dữ liệu, Chờ xử lý); tên kỹ thuật của "chỉ số mức độ sạch" đổi từ dq_result sang view v_batch_score; wireframe dùng "hồ sơ nghi trùng" thay cho "bản dư thừa"; tên cột nguồn dùng đúng header thật (ho_ten, so_dien_thoai). |
| **Phép 2 – Truy vết** | Bản Buổi 4 có 11 User Story, vượt giới hạn 5 – 7 → gộp còn 7; US10 thành mục WON'T W1; US11 thành ràng buộc QT-15. Bảng truy vết thêm cột bảng dữ liệu và khung màn hình; 0 ô trống, kể cả hàng WON'T. |
| **Phép 3 – Kiến trúc ↔ dữ liệu** | 11 tên bảng ở lớp lưu trữ (Hình 3.1) khớp 100% với Hình 4.2 và Hình 4.3. |
| **Phép 4 – Wireframe ↔ dữ liệu** | Mọi trường trên K1 – K4 có cột nguồn (Bảng 5.1); 11/11 bảng xuất hiện ở ít nhất một khung hoặc báo cáo. |
| **Phép 5 – Lập luận ↔ yêu cầu** | 4 câu lập luận đều có mã NFR, ngưỡng số, quyết định và đánh đổi (mục 3.2). |
| **Phép 6 – Ngoại lệ ↔ giao diện** | 6 luồng ngoại lệ của UC5 (3a, 3b, 5a, 8a, 8b, 9a) đều có chỗ hiển thị ở vùng thông báo của K4; dashboard có thông báo trạng thái rỗng (K1). |
| **Bước 5 – Soi 5 lỗi ERD** | Xem Bảng 4.2: bỏ giá trị tính được và dòng tổng ở dq_result, sửa khóa ngoại hai phía của dup_candidate, thêm chỉ mục, khóa chính đều là khóa thay thế. |

## B.3. Nhật ký thay đổi

| # | Thay đổi | Lý do / căn cứ | Vị trí |
|---|---|---|---|
| 1 | User Story 11 → 7: gộp US4 + US5 cũ thành US4; gộp US7 + US8 cũ thành US6; US10 → WON'T W1; US11 → ràng buộc QT-15 (FR-11, NFR-07); đánh số lại US1 – US7; bỏ dẫn chiếu V4 ở story báo cáo. | Đề bài yêu cầu 5 – 7 User Story; case study ánh xạ V4 tới L6, L10, không phải L7. | 1.3, B.4 |
| 2 | FR-05, FR-08, FR-11 nâng từ SHOULD lên MUST; việc tạo name_key chuyển từ FR-03 sang FR-04; mã lỗi MISSING_NAME và việc ghi hồ sơ hợp lệ vào customer_clean ghi rõ ở FR-02. | UC4, UC7 là bước bắt buộc («include») của use case MUST (UC5; UC1, UC5) nên xếp SHOULD là mâu thuẫn; FR-11 thực hiện quy tắc bắt buộc QT-15; FR-04 (MUST) chấm điểm trên name_key nên không được phụ thuộc FR-03 (SHOULD); customer_clean.full_name là NOT NULL nên kiểm MISSING_NAME phải thuộc bước MUST. | 1.3, 1.6 |
| 3 | Cột nguồn giả định (full_name, phone, address, source, created_at) → header thật record_id, ho_ten, so_dien_thoai, email, dia_chi, ngay_tao; FR-01 kiểm cột ho_ten, so_dien_thoai. | Đối chiếu header thật của customers_raw.csv (bản Buổi 4 ghi là giả định). | 1.3, 4.1 |
| 4 | Điền tỉ lệ thiếu từng cột bằng số đo thật: so_dien_thoai 6,17%, email 44,99%, dia_chi 8,98%, ho_ten 0%, ngay_tao 0%. | Việc còn dở ghi trong báo cáo Buổi 4. | 4.1 |
| 5 | Trích mẫu ngẫu nhiên theo dòng (6.000) → trích theo cụm số điện thoại (8.000 dòng, seed 42). | Đo: mẫu cũ chỉ còn 1,64% hồ sơ lặp nên không kiểm được US3, US4. | 4.1, Hình 4.1 |
| 6 | Bỏ khóa blocking "cùng tên gọi", giữ "cùng 5 số đầu hoặc 5 số cuối". | Đo: khóa tên gọi (44 giá trị) thêm 639.483 phép so sánh và chỉ tìm thêm 1 cặp dương tính giả. | FR-04, 3.2 |
| 7 | Sinh cặp EXACT_PHONE theo hồ sơ nạp sớm nhất (k − 1 cặp mỗi nhóm). | Tránh cặp phụ thuộc nhau khi gộp nhóm 3 hồ sơ. | QL7-02 |
| 8 | Use Case: thêm «include» UC5 → UC7, bố trí lại thành hai cột; đổi tên UC1, UC3, UC8 theo bảng thuật ngữ (tệp khách hàng thô, cặp nghi trùng, dashboard). Đặc tả UC5: thêm dòng "User Story liên quan"; bước 8 và luồng 3a khóa cặp, kiểm tra lại trạng thái (6a cũ thành 8a, 8a cũ thành 8b); 3a gọi UC7. | Khớp bước 9 của đặc tả và bảng thuật ngữ; đủ các mục đặc tả theo đề bài; tránh hai người cùng quyết định một cặp. | 2.1, 2.2 |
| 9 | Bảng actor thêm cột "Không được làm". | Đề bài yêu cầu nêu việc mỗi vai trò không được làm. | 1.2 |
| 10 | dq_result: bỏ pass_rate, weighted_score và "dòng tổng" (rule_id NULL); thêm measure_stage. | Lỗi lưu giá trị tính được, trộn hai mức chi tiết; cần so TRƯỚC/SAU. | 4.3 |
| 11 | dup_candidate: record_a/record_b → stg_id_a/stg_id_b (khóa ngoại tới stg_customer); bỏ phone_sim, name_sim, batch_id; thêm detected_at. | Khóa ngoại phải trỏ về một bảng xác định; tránh giá trị tính được và phụ thuộc bắc cầu. | 4.3 |
| 12 | stg_customer: flags (nhiều giá trị trong một cột) → error_code; thêm customer_id, source_record_id, created_raw. customer_clean: UNIQUE(phone) chỉ trên hồ sơ đang hiệu lực. load_batch: thêm source_unit. dq_rule: thêm updated_by, updated_at. | Đạt 1NF; truy vết hồ sơ thô → hồ sơ đã làm sạch; gộp không vi phạm QT-01; phục vụ QT-14 và SCD loại 2. | 4.3, Phụ lục A |
| 13 | Thêm kho dữ liệu dwh: dim_date, dim_batch, dim_rule (SCD loại 2), fact_dq_check, fact_dup_pair và 2 view. | Sản phẩm bắt buộc của track DA; dashboard chỉ đọc kho (NFR-06). | 4.4 |
| 14 | Quy tắc DQ ghi rõ mẫu số (phạm vi áp dụng) từng quy tắc; DQ-02 tính trên hồ sơ có số điện thoại. | Tránh phạt hai lần hồ sơ thiếu số (đã tính ở DQ-01). | 4.5 |
| 15 | Câu hỏi phân tích Q6 diễn đạt lại: số điện thoại sai dạng đã sửa được nhờ chuẩn hóa và số hồ sơ thiếu số không sửa được. | Đo: sau chuẩn hóa không còn số nào sai dạng (0 số không quy về được). | K2; data-requirements.md |
| 16 | Đổi tên tệp: data-requirement-spec.md → data-requirements.md; usecase_L7.drawio → usecase.drawio; chuyển hồ sơ sang repo dự án (thư mục docs/). | Đúng cấu trúc thư mục tối thiểu của đề bài. | Repo |
| 17 | NFR-05 bổ sung: nạp lại vào CSDL mới khởi tạo; chỉ số của lần đo đã có không đổi khi cấu hình quy tắc thay đổi. | Nạp lại cùng tệp vào CSDL đang có sẽ sinh cặp trùng giữa hai đợt; căn cứ cho SCD loại 2 của dim_rule. | 1.4, 3.2 |

## B.4. Ánh xạ User Story Buổi 4 → Buổi 6

| Buổi 4 | Buổi 6 | Ghi chú |
|---|---|---|
| **US1** | US1 | Giữ nguyên |
| **US2** | US2 | Giữ nguyên |
| **US3** | US3 | Giữ nguyên |
| **US4 + US5** | US4 | Gộp: xem danh sách là bước bắt buộc của xác nhận (UC5 «include» UC4) |
| **US6** | US5 | Đánh số lại |
| **US7 + US8** | US6 | Gộp: tính chỉ số (UC7) phục vụ trực tiếp việc xem dashboard (UC8) |
| **US9** | US7 | Đánh số lại |
| **US10** | W1 (WON'T) | Chuyển vào danh sách chủ ý không làm |
| **US11** | QT-15 (FR-11, NFR-07) | Yêu cầu bảo mật từ quy tắc nghiệp vụ, không phải mục tiêu của actor |

# PHỤ LỤC C – BẢNG KHAI BÁO SỬ DỤNG CÔNG CỤ AI (BẮT BUỘC)

Khai báo theo mục 2.6 của đề bài Bài tập 1.

| Công cụ | Dùng vào việc gì | Áp dụng ở phần nào | Đã kiểm chứng thế nào |
|---|---|---|---|
| Claude | Sử dụng AI để tham khảo cách trình bày, rà soát nội dung và đề xuất hướng triển khai bài tập. Cụ thể, AI hỗ trợ rà soát hồ sơ Buổi 4 theo checklist, đề xuất chỉnh sửa tại Phụ lục B, xây dựng và chạy script profiling dữ liệu customers_raw.csv, soạn bản nháp mục 3, 4, 5, chỉnh sửa sơ đồ Use Case, tạo các tệp .drawio, Markdown cho repo và hỗ trợ dàn trang tài liệu. | Mục 1, 2 (cập nhật theo Phụ lục B), mục 3, 4, 5, Phụ lục A, B; docs/*.drawio, docs/*.md, README.md; notebooks/profiling_customers.py | chạy lại script profiling với seed 42 và đối chiếu từng con số ở mục 4.1, 4.5; mở từng tệp .drawio bằng draw.io để đối chiếu với hình; đọc lại, sửa câu chữ 4 câu lập luận và tự giải thích được GRAIN, SCD loại 2 |

**Tôi xác nhận đã đọc, hiểu và chịu trách nhiệm về toàn bộ nội dung nộp.**

Họ tên: Dương Diễm My · MSSV: 2374802010318 · Ngày: 09/10/2026

Chữ ký: Dương Diễm My